

Rapport de Visualisation du fichier PCA

Réduction de dimension (PCA) et clustering des profils de consommation énergétique

Table des matières

1 Contexte	1
2 Méthodologie	
2.1 Préparation des données.	1
2.2 Standardisation	1
2.3 PCA à 2 composantes	1
2.4 PCA à 95% de variance expliquée.	1
2.5 Clustering avec K-Means.	2
3 Analyse des résultats	
3.1 PCA à 2 composantes.	2
3.2 PCA à 95% de variance.	3
3.3 Clustering sans PCA.	3
3.4 Clustering avec PCA.	5
2 Conclusion	7

Objectif

Le fichier *PCA.ipynb* cherche à comprendre les profils journaliers de consommation électrique d'un bâtiment à partir de données horaires sur une année.

D'abord, l'objectif est de réduire le nombre de variables qui décrivent chaque journée (24 valeurs horaires) tout en conservant le maximum d'informations, grâce à une Analyse en Composantes Principales (PCA). Ensuite, il s'agit de vérifier si cette réduction de dimension aide à regrouper les journées qui se ressemblent (clustering), en comparant les résultats obtenus avec et sans PCA. L'idée de fond est de savoir si la PCA est un outil utile pour simplifier des données de consommation énergétique avant de les analyser ou de les utiliser dans un modèle prédictif.

Méthodologie

2.1 Préparation des données

Pour l'analyse en PCA, nous avons repris le tableau pivot de Damien où chaque ligne représente un jour de l'année et chaque colonne une heure de la journée (de 0 à 23), la valeur étant la consommation totale à cette heure. Chaque jour est donc décrit par un vecteur de 24 variables (les 24 heures).

2.2 Standardisation

Nous avons appliqué un *StandardScaler* pour centrer et réduire les 24 variables horaires. En effet, sans standardisation, les heures où la consommation était naturellement plus élevée (et plus variable, par exemple en soirée) auraient dominé la PCA, uniquement parce que leur variance brute était plus grande. En standardisant, nous avons donné le même poids à chaque heure de la journée, ce qui a permis à la PCA de capturer la forme de la courbe de consommation (le profil horaire) plutôt que son niveau (l'amplitude absolue). Nous avons volontairement gardé les deux versions dans le notebook : les données brutes x (qui reflètent le niveau d'amplitude) et les données standardisées X (qui reflètent la forme), afin de comparer leurs effets sur la PCA et sur le clustering.

2.3 PCA à 2 composantes

Nous avons commencé par une PCA à 2 composantes sur les données standardisées, dans le seul but de visualiser les 365 jours sur un plan en 2 dimensions. Nous avons également affiché les coefficients (loadings) de chaque heure sur les deux premières composantes, ainsi que la formule mathématique explicite de chaque composante, pour comprendre quelles heures pesaient le plus dans chaque axe.

2.4 PCA à 95% de variance expliquée

Nous avons ensuite refait la PCA en demandant à *sklearn* de garder automatiquement le nombre de composantes nécessaires pour expliquer 95% de la variance totale. Nous avons fait ce calcul deux fois, une fois sur les données standardisées, une fois sur les données brutes. Cela nous a permis de voir combien de variables étaient réellement nécessaires pour représenter fidèlement les journées, et si ce nombre changeait selon que l'on travaillait sur la forme ou sur l'amplitude.

2.5 Clustering avec K-Means

Pour évaluer l'utilité de la PCA, les jours ont été regroupés en clusters grâce à l'algorithme K-Means, à la fois sur les données originales (24 variables) et sur les données réduites par PCA. Pour choisir le nombre optimal de clusters k , nous avons repris et adapté le code de Yasmin qui combine la méthode du coude et le score de silhouette. Quand la méthode du coude ne détectait pas de coude net, le k qui maximise le score de silhouette a été choisi, ce qui a garanti une valeur de repli assez cohérente.

Une fois les clusters formés, nous les avons caractérisés de plusieurs façons grâce aux visualisations de Yasmin :


- Répartition par jour de la semaine (semaine/weekend),
- Répartition par mois,
- Profils moyens par cluster (avec écart-type),
- Position des clusters le long de la chronologie de l'année.

Nous avons répété cette évaluation sur les données brutes sans PCA, standardisées sans PCA, brutes avec PCA et standardisées avec PCA afin de comparer les résultats.

Analyse des résultats

3.1 PCA à 2 composantes

Avec seulement 2 composantes, nous expliquons 8,72% de la variance pour la première composante et 7,21% pour la deuxième, soit environ 16% de la variance totale. Ce chiffre est faible. Cela s'explique probablement par le fait que les variables ont été standardisées, car chaque heure porte une part de variance assez proche des autres, donc aucune paire de composantes ne peut capturer la majorité de l'information. Ce résultat n'est pas un problème en soi car le but de cette PCA à 2 composantes est uniquement de visualiser un aperçu global du nuage de points.



Le nuage de points obtenu (projection des 365 jours sur les 2 premières composantes) forme une masse assez continue, sans séparation nette en groupes bien distincts. Cela signifie que les journées ne se répartissent pas naturellement en catégories très tranchées en 2D. On peut émettre l'hypothèse que le clustering ne trouvera pas forcément des groupes très nettement séparés.

L'analyse des coefficients terme à terme dans l'équation montre que la première composante oppose les heures de fin de matinée et d'après-midi (poids positifs élevés vers 6h-9h) aux heures de nuit et de début

de matinée (poids négatifs vers 0h-2h et 13h-15h). La deuxième composante met davantage en avant les heures de milieu de journée (3h-6h dans l'échelle utilisée). Ces deux axes résument donc essentiellement des oppositions entre différents moments de la journée, ce qui est cohérent avec l'idée que la PCA capture ici la forme du profil horaire.

FORMULES EXPLICITES

1ère composante = $-0.221 * 0 - 0.347 * 1 - 0.068 * 2 - 0.064 * 3 + 0.063 * 4 + 0.044 * 5 + 0.286 * 6 + 0.425 * 7 + 0.365 * 8 + 0.189 * 9 - 0.074 * 10 - 0.175 * 11 - 0.197 * 12 - 0.187 * 13 - 0.302 * 14 - 0.290 * 15 - 0.172 * 16 - 0.145 * 17 - 0.099 * 18 + 0.058 * 19 - 0.068 * 20 - 0.109 * 21 - 0.037 * 22 - 0.138 * 23$

2ème composante = $-0.076 * 0 + 0.085 * 1 + 0.284 * 2 + 0.444 * 3 + 0.373 * 4 + 0.429 * 5 + 0.150 * 6 - 0.004 * 7 - 0.139 * 8 - 0.237 * 9 - 0.238 * 10 - 0.242 * 11 - 0.129 * 12 - 0.275 * 13 - 0.078 * 14 + 0.112 * 15 + 0.105 * 16 + 0.069 * 17 + 0.181 * 18 + 0.051 * 19 - 0.031 * 20 + 0.054 * 21 + 0.069 * 22 + 0.047 * 23$


3.2 PCA à 95% de variance

Sur les données standardisées, il faut garder 22 composantes sur 24 variables initiales pour conserver 95% de la variance. Sur les données brutes (non standardisées), il faut 19 composantes sur 24 pour atteindre au moins 95% de variance, et la première composante à elle seule explique 10,32% (contre 8,72% en standardisé).

Le nombre élevé de composantes à conserver pour couvrir 95% de la variance montre que l'information n'est pas concentrée sur quelques axes, mais est plutôt distribuée de façon assez homogène sur presque toutes les heures de la journée.


La différence entre standardisé et brut montre que la standardisation "égalise" l'importance des heures et rend la structure des données un peu plus complexe à résumer, alors que sur les données brutes, les heures à forte variance naturelle (comme les heures de pointe) dominent davantage et permettent une réduction légèrement plus efficace. Dans les deux cas, la conclusion pratique est que la PCA ne permet pas ici une réduction de dimension forte tout en gardant l'essentiel de l'information. Elle est donc peu utile comme outil de compression pour ce type de données horaires.

3.3 Clustering sans PCA




Sur les données brutes (niveau d'amplitude), la méthode du coude identifie k=10 comme nombre optimal de clusters, mais les scores de silhouette restent bas sur toute la plage testée (entre 0.05 et 0.10). Sur les données standardisées (forme), aucun coude n'est détecté par l'algorithme. Nous retenons alors k=2, la valeur qui maximise le score de silhouette (0,1021), lui aussi assez faible. Ces scores de silhouette confirment que les clusters ne sont pas nettement séparés.

Profil journalier par rapport à la quantité d'énergie consommée (amplitude/brut) (k=10)




Le clustering en k=10 sur les données brutes produit des groupes de tailles très inégales (de 18 à 109 jours). L'analyse de la composition des clusters (répartition semaine/weekend et répartition mensuelle) montre que sur les données brutes à k=10, le cluster 5 est nettement plus présent le weekend (environ 65%) que les autres, et le cluster 2 ne contient que des jours de semaine. Les autres clusters mélangent semaine et weekend de façon plus homogène, ce qui veut dire que le facteur dominant du clustering brut est lié de manière secondaire au type de jour.




Sur les données normalisées, seuls k=2 seuls clusters sont formés. Cette séparation binaire établit 2 groupes qui semblent suivre des motifs opposés selon le graphique de visualisation. Leur taille est relativement similaire (200 vs 165 bâtiments)

Profil journalier par rapport à la forme d'énergie consommée (forme/normalisé) (k=2)




Tandis que l'un des clusters est composé à 90% de jours de semaine, l'autre contient autant de jours de semaine que de jours de weekend. Comme ce dernier cluster est plus petit, l'équilibre pourrait venir d'une difficulté du modèle à séparer les jours de semaine en vacances, ou la consommation d'énergie est similaire aux week-ends, des jours de travail. On remarque de plus que le cluster 2 semble regrouper davantage de saisons froides/hivernales allant de novembre à février, et le cluster 1 les saisons intermédiaires et d'été. On peut alors supposer que le cluster 2 regroupe les consommations d'énergies plus élevées.

Composition temporelle des clusters (forme/normalisé)




3.4 Clustering avec PCA

Après réduction PCA, la méthode du coude propose $k=8$ sur les données brutes réduites par PCA (contre $k=10$ sans PCA), avec des scores de silhouette aussi autour de 0,08.



Sur les données standardisées réduites par PCA on obtient un nombre de clusters de $k=6$ (contre $k=2$ sans PCA), avec un score de silhouette maximal comparable (0,1067).



Ce résultat est la conclusion la plus importante concernant l'utilité de la PCA pour le clustering : la PCA ne fait pas apparaître de structure de clusters plus nette que les données originales. Les scores de silhouette restent dans la même fourchette basse, avec ou sans réduction de dimension. Cela confirme que puisque l'information est distribuée sur presque toutes les composantes (19 à 22 sur 24), réduire la dimension revient surtout à perdre un peu d'information sans simplifier la structure sous-jacente des données. La PCA change légèrement le nombre de clusters optimal détecté par la méthode du coude, mais elle n'améliore pas la qualité de séparation des groupes.

CONCLUSION

Pour conclure, les scores de silhouette obtenus, systématiquement bas (entre 0,03 et 0,11), montrent que les clusters trouvés ne sont pas très bien séparés, et donc la lecture des résultats de clustering reste donc plutôt indictaive. Enfin, la PCA appliquée ici montre ses limites sur ce type de données très peu redondantes et ne permet ni une forte compression, ni une amélioration du clustering, ce qui est un résultat en soi mais qui restreint son intérêt pratique dans notre contexte précis.

Les limites de cette analyse sont à la fois l'unicité du bâtiment analysé et de la variable discriminante (courbe de consommation totale horaire). Une piste possible serait d'intégrer plus de bâtiments et de variables d'analyse.

Ces résultats donnent cependant des indications utiles pour la prédiction de la consommation énergétique d'un bâtiment. En effet, le constat que la PCA appliquée aux 24 variables horaires ne réduit pas franchement la dimension suggère que, pour les variables de type temporelles, la PCA seule ne sera probablement pas suffisante pour condenser l'information avant la modélisation. Par contre, elle pourra sans doute être appliquée sur les variables de type statique (superficie, revenu) afin de réduire leur nombre et de créer un seul indicateur.