

# Du BigData bâtimentaires au modèle prédictif :

modéliser et regrouper la consommation  
électrique résidentielle

Projet FlexiMax : MINES Paris-PSL / ARMINES  
Stage de 4 mois : Polytech Nice Sophia

Yassmin Zouarhi

Encadrants : Gilles Guerassimoff, Damien Corral, Abderrahmane Habbal




1. Contexte : FlexiMax et le jeu de données ResStock
2. Les données : métadonnées et séries temporelles
3. De la donnée brute à la feature physique
4. Modèle prédictif de référence (LightGBM)
5. Dynamique temporelle : clustering des régimes de consommation
6. Limites et perspectives

**FlexiMax** : projet MINES Paris-PSL / ARMINES (France 2030 / ADEME) sur la flexibilité énergétique résidentielle.

- Objectif de stage : **prédire la consommation électrique et le potentiel de flexibilité** d'un bâtiment à partir de ses caractéristiques
- Nécessite un jeu de données *important, standardisé, physiquement fondé*

Aucune base résidentielle **française** comparable disponible  $\Rightarrow$  recours à **ResStock** (NREL, USA).  
Solution = parc *américain* (confort thermique, habitudes de vie, mobilité, électroménager). Transposition à revalider.



ResStock 2025 Release 1 : 549 971 bâtiments  $\times$  771 colonnes,  
50 états

**Métadonnées** : 549 971 bâtiments, 771  
→ 391 colonnes après nettoyage.

- **165 features** : caractéristiques du bâtiment


| Groupe in.*                   | Col. |
|-------------------------------|------|
| Localisation                  | 21   |
| Zone climatique               | 5    |
| Géométrie du bâtiment         | 20   |
| Enveloppe thermique           | 17   |
| HVAC                          | 42   |
| Eau chaude                    | 6    |
| Appareils électroménagers     | 28   |
| Véhicule électrique           | 6    |
| Panneau électrique            | 2    |
| Solaire et stockage           | 4    |
| Occupants et socio-économique | 13   |

**5 cibles** candidates dans les résultats de simulation, l'électricité retenue.

La modélisation sera focalisée sur le périmètre **tout-électrique** (64 062 logements).

**Séries temporelles** : dynamique fine par bâtiment, en complément des métadonnées annuelles.

- Pas **15 minutes** (35 040 points/an)
- Météo horaire par zone climatique



Exemple de profil journalier

### Encodage selon la nature de chaque variable :

| Type de variable   | Méthode d'encodage                            | Exemple                 |
|--------------------|-----------------------------------------------|-------------------------|
| Numérique continue | valeur conservée telle quelle                 | latitude, longitude     |
| Catégorie ordonnée | lookup table officielle (guide ResStock)      | isolation → valeur R    |
| Code composite     | extraction numérique dans la chaîne           | cote d'efficacité       |
| Catégorie nominale | one-hot / binaire                             | type de chauffage       |
| Variable cyclique  | circulaire, sin / cos ( $0^\circ=360^\circ$ ) | orientation du bâtiment |

**165 attributs bruts → 108 encodés**

dont 32 pour l'enveloppe thermique (30%) ⇒ agrégation physique

Les 5 agrégats reprennent les termes du modèle **RC** (résistance-capacité), standard en thermique du bâtiment : flux de chaleur et capacité de stockage du schéma ci-contre.

$UA = \sum_i U(R_i)A_i + U_{\text{fen}}A_{\text{fen}}$  (W/K) : pertes par transmission (murs, toit, fenêtres)


$H_{\text{ve}} = 0,34 \cdot \frac{\text{ACH50}}{20} \cdot V$  (W/K) : pertes par infiltration/renouvellement d'air

$C = C_{\text{classe}} \times A_{\text{pl}}$  (kJ/K) : inertie thermique

$A_{\text{solaire}} = \text{SHGC} \times 0,9 \times \sum A_{\text{fen}} \times p(\theta)$  (m<sup>2</sup>) : gains solaires équivalents ( $Q_{\text{ext}}$ )

compacité =  $\frac{\sum A}{V}$  (m<sup>-1</sup>) : coefficient de forme du bâtiment


**30 attributs bruts → 5 grandeurs physiques**




Bilan énergétique d'un bâtiment : pertes (toit 42%, murs 24%, fenêtres 12%, cheminée 12%, sol 10%) et gains internes/externes  $Q_{\text{int}}$ ,  $Q_{\text{ext}}$

# Modèle prédictif de référence : LightGBM

Comparaison des modèles LightGBM — cible électricité




Modèle final LightGBM + sélection SHAP  
out.electricity.total.energy\_consumption..kwh



LightGBM (boosting de gradient sur arbres), cible **consommation électrique annuelle**, périmètre **tout-électrique** (64 062 logements), split catégorisé par zone ASHRAE :  $R^2 = 0,9254$ , RMSE = 2712 kWh (13,8%). Jeu **Physique** : les 5 agrégats pèsent **32,3%** de l'importance.

# Clustering : construire le vecteur de 23 dimensions

**100 bâtiments tout-électriques**, séries horaires  $\Rightarrow$  **36 500 jours**, **niveau** et **forme** propres à chacun (jusqu'à  $\times 23$  d'écart), décrits par 3 blocs de variables :



**Forme** (z-score intra-jour)


$$x_{j,i}^{\text{forme}} = (x_{j,i} - \bar{x}_j) / \sigma_j$$

**Amplitude** (par bâtiment)

$$x_j^{\text{amp}} = (\log(1+x_j) - \mu_b) / \sigma_b$$

Le choix « par bâtiment », pas globalement, sépare les jours atypiques *pour ce logement*, pas les gros logements des petits.


# Clustering : réduire le profil 24 h par PCA




**Pourquoi 10 dimensions et pas 24 (une par heure) ?** La PCA compresse le profil horaire en gardant l'essentiel de sa variabilité : 10 composantes suffisent pour 80%, le seuil retenu. Atteindre 95% demanderait 19 composantes, mais l'objectif est de séparer des régimes, pas de reconstruire fidèlement la courbe.

PCA sur  $X \in \mathbb{R}^{n \times 24}$  standardisée : diagonalise  $C = \frac{1}{n} X^T X$ , valeurs propres  $\lambda_1 \geq \dots \geq \lambda_{24}$ .  
Variance de la composante  $k$  :  $\lambda_k / \sum_i \lambda_i$ . Cumulée sur 10 :  $\sum_{k=1}^{10} \lambda_k / \sum_i \lambda_i = 80\%$ .

# Clustering : choix de $k$ et résultat



Avant tout traitement : aucune structure visible à l'œil nu



Axe matin vs soir : pics 6-8h ou 16-17h selon cluster, visible seulement à l'échelle du panel

Méthode du coude  $\Rightarrow$   **$k=6$** , retenu pour sa richesse interprétable.


**Aucun bâtiment**  $>4\%$  d'un cluster :  
régimes partagés, pas des identités recyclées.  
Tailles entre 4 300 et 12 500 jours, aucune marginale.

# Clustering : classifier un nouveau jour

Une fois le K-means entraîné, un jour jamais vu peut être classé dans un régime existant, sans réentraîner : mêmes transformations, puis `kmeans.predict()`.




Sur un bâtiment **jamais vu** (410562, Kentucky) : marge de confiance médiane = **1,29**, contre **1,09** pour le panel d'entraînement. La classification y est même plus nette que sur les données d'entraînement.



**Perspective** : avec une prévision météo, ce mécanisme permet d'anticiper le régime probable d'un jour à venir, un premier pas vers des leviers de flexibilité, l'objectif initial du programme FlexiMax.

# Clustering : lecture métier des 6 régimes



Le **chauffage** domine les régimes froids (clusters 1, 3, 4, 5) ; la **climatisation** domine le cluster majoritaire et le plus chaud (2, n=12 526, pic 17 h).

## Bilan

- Chaîne complète et reproductible : nettoyage → encodage → agrégation physique → LightGBM ( $R^2 = 0,925$ )
- Clustering des régimes journaliers : 6 profils métier, lien climat/usage lisible à toutes les échelles
- Classification d'un nouveau jour validée hors panel

## Limites

- Parc **américain**, non transposable tel quel
- Clustering sur **100 bâtiments**, une seule année météo
- Comportement individuel des occupants non capturé

## Perspectives


- Étendre le clustering au périmètre complet (64 062 logements), revalider sur données françaises
- Relier les régimes à des leviers de flexibilité (effacement, pilotage HVAC)
- Combiner prévision et régimes dans un outil de pilotage prédictif unique

# Merci pour votre attention

Questions ?

**En une phrase** : du nettoyage des métadonnées brutes à la prévision, une chaîne complète et reproductible. Le climat structure la consommation à toutes les échelles (annuelle, journalière, horaire), et le clustering des régimes journaliers ouvre la voie à des leviers de flexibilité concrets.

## Annexe : méthode du coude et score de silhouette



Méthode du coude  $\Rightarrow$  **k=6**, mais silhouette maximale à  $k=2$  (0,33) puis décroît : signal d'un *continuum* de comportements plus que de régimes nettement séparés.  $k=6$  gardé pour sa richesse interprétable (température, axe matin/soir), la typologie reste utile pour *décrire* le panel, pas une segmentation définitive.