



Rapport de stage

FlexiMax - Flexibilité énergétique résidentielle

Prédiction de la consommation énergétique à partir des données ResStock

MINES Paris - PSL / ARMINES

Programme France 2030 - ADEME

Yassmin Zouarhi

Stage de 4 mois, 2025/2026

Encadrants : *Gilles Guerassimoff, Damien Corral, Abderrahmane Habbal*

8 septembre 2026



Pipeline de notebooks : 01_exploration → 02_nettoyage → 03_visualisation → 04_features → 05_deeplearning
→ 06_timeseries - dépôt FlexiMax

Remerciements

Je tiens à remercier chaleureusement mes deux tuteurs de stage, Gilles Guerassimoff et Damien Corral, pour leur suivi régulier, leur disponibilité et leurs conseils tout au long de ce projet, ainsi que pour la confiance accordée dans la conduite des différentes étapes de l'analyse.

Je remercie également Abderrahmane Habbal, mon tuteur académique à Polytech, pour son accompagnement et le suivi pédagogique apporté durant ce stage.

Mes remerciements vont aussi à Didier Auroux, responsable de stage de la filière MAM à Polytech, pour son suivi et sa disponibilité tout au long de cette expérience.

Je souhaite aussi remercier l'ensemble de l'équipe du programme FlexiMax à MINES Paris - PSL / ARMINES pour son accueil et pour les échanges enrichissants sur les enjeux de flexibilité énergétique résidentielle, ainsi que pour l'accès aux données et aux outils nécessaires à la réalisation de ce travail.

Merci également à Boubaker Amdyoun, avec qui j'ai partagé ce dépôt de travail, pour les échanges techniques et méthodologiques qui ont permis d'améliorer la fiabilité des analyses présentées dans ce rapport.

Je remercie aussi Eyua Assoumou, stagiaire ayant rejoint l'équipe pour un mois, qui nous a aidés à lancer l'exploration des séries temporelles.

Enfin, je remercie le programme France 2030 et l'ADEME pour le financement de ce projet de recherche.

Résumé

Combien d'électricité un bâtiment résidentiel va-t-il consommer, et pourquoi ? Ce stage, mené dans le cadre du programme FlexiMax (MINES Paris - PSL / ARMINES, France 2030 / ADEME), construit pas à pas une chaîne de modélisation de la consommation énergétique résidentielle. En l'absence de données disponibles sur le projet FlexiMax lui-même au moment du stage, ce travail s'appuie sur un cas d'étude alternatif : les données de simulation ResStock (NREL) - près de 550 000 bâtiments, chacun décrit par plusieurs centaines de variables et une série temporelle horaire sur un an.

L'exploration révèle que, sous les 771 colonnes brutes du jeu de métadonnées, se cachent des doublons et artefacts de simulation (391 colonnes retenues) ; un même facteur revient sans cesse, la zone climatique. Elle structure la consommation de chauffage/climatisation, borne le potentiel de flexibilité des thermostats (43,8 % seulement des bâtiments disposent d'un thermostat programmable pour le chauffage), et réapparaît comme déterminant n°1 du modèle prédictif final. Ce fil conducteur, la géographie climatique comme clé de lecture de la consommation, traverse tout le rapport, de l'exploration au clustering des profils journaliers jusqu'à l'importance des variables du modèle LightGBM.

Pour la cohérence du périmètre, l'analyse se recentre ensuite sur les bâtiments **tout-électriques**. Un pipeline de feature engineering réduit 108 attributs bruts à 83 features physiquement interprétables, dont cinq agrégats d'enveloppe qui remplacent une trentaine de variables catégorielles propres au parc états-unien. Un modèle LightGBM entraîné sur ce périmètre atteint un R^2 de 0,925 sur la consommation électrique - contre 0,845 avant le recentrage tout-électrique - avec un écart minime face au jeu de features réduit aux seuls agrégats physiques. Le clustering des profils journaliers révèle ensuite des « jours types » récurrents, à l'échelle d'un bâtiment puis d'un panel de 100 logements, avant qu'une architecture hybride RNN/MLP n'explore deux horizons de prédiction sur les séries horaires : prévoir la consommation à l'heure suivante ($R^2 = 0,877$) et extrapoler la consommation annuelle à partir de 90 jours d'observation ($R^2 = 0,803$).

Le rapport livre ainsi moins une collection de modèles qu'une lecture cohérente des déterminants de la consommation électrique résidentielle, et une chaîne reproductible pour l'étendre.

Abstract

How much electricity will a residential building draw, and why ? This internship, carried out within the FlexiMax program (MINES Paris - PSL / ARMINES, France 2030 / ADEME), builds step by step a residential energy consumption modelling pipeline. With no data yet available on the FlexiMax project itself at the time of the internship, this work relies on an alternative case study : the ResStock simulation dataset (NREL) - close to 550,000 buildings, each described by hundreds of attributes and a full year of hourly time series.

Exploration shows that behind the 771 raw metadata columns lie duplicates and simulation artifacts (391 columns retained) ; one factor keeps resurfacing, the climate zone. It shapes heating/cooling consumption, bounds thermostat flexibility potential (only 43.8% of buildings have a programmable heating thermostat), and later re-emerges as the top determinant of the final predictive model. This thread, climate geography as the key to reading consumption, runs through the report, from metadata exploration to daily-profile clustering to LightGBM feature importance.

For scope coherence, the analysis then focuses on **all-electric** buildings. A feature engineering pipeline reduces 108 raw attributes to 83 physically interpretable features, including five envelope aggregates that replace about thirty categorical variables specific to the US housing stock. A LightGBM model trained on this scope reaches an R^2 of 0.925 on electricity consumption, versus 0.845 before the all-electric recentring, with only a small gap versus the feature set reduced to the physical aggregates alone. Clustering the daily profiles then reveals recurring "typical days", at the scale of a single building and of a 100-building panel, before a hybrid RNN/MLP architecture tackles two prediction horizons on the hourly series : forecasting next-hour consumption ($R^2 = 0.877$) and extrapolating annual consumption from 90 days of observation ($R^2 = 0.803$).

The report thus delivers less a collection of models than a coherent reading of what drives residential electricity consumption, and a reproducible pipeline to extend it.

Table des matières

Remerciements	1
Résumé	2
1 Contexte : le stage, FlexiMax et les données	7
1.1 Le jeu de données ResStock	7
1.2 Nettoyage des métadonnées	8
1.3 Structure du jeu nettoyé : variables <code>in.*</code> et <code>out.*</code>	8
1.3.1 Variables <code>in.*</code>	8
1.3.2 Variables <code>out.*</code>	9
2 Le climat, premier déterminant de la consommation	10
2.1 Localisation et zone climatique	10
2.2 Une dispersion que le climat seul n'explique pas	11
3 Au-delà du climat : bâti, équipements et comportement	13
3.1 Enveloppe thermique	13
3.2 Système HVAC	13
3.3 Occupants et profil socio-économique	14
3.4 Classification métier des variables	14
3.5 Décomposition nationale par usage et par vecteur énergétique	16
4 De la donnée brute à la feature physique	18
4.1 Principe d'encodage	18
4.2 Agrégation physique de l'enveloppe	19
5 Modélisation	20
5.1 Un modèle LightGBM sur le périmètre tout-électrique	20
5.2 Global vs Physique : le compromis interprétabilité	20
5.3 Performance par usage électrique	21
6 Dynamique temporelle	23
6.1 Jours types : clustering du profil journalier d'un bâtiment de référence	23
6.2 Vers un clustering à l'échelle du panel	26
6.3 Un modèle hybride RNN+MLP pour deux horizons de prédiction	28
7 Discussion et limites	30
7.1 Portée et transférabilité	30
7.2 Limites méthodologiques	30
7.3 Choix de modélisation écartés	30
8 Conclusion et perspectives	31
8.1 Synthèse	31
8.2 Perspectives	31
Bibliographie	32

A	Annexes	33
A.1	Description détaillée des attributs in.* encodés	33
A.2	Pipeline complet des notebooks	39
A.3	Profils moyens par cluster en valeurs réelles	39

Table des figures

1.1	Colonnes gardées vs supprimées par groupe (771 → 391 colonnes).	8
2.1	Top 20 états par nombre de bâtiments et par consommation électrique moyenne ; consommation moyenne par région Census.	10
2.2	Nombre de bâtiments simulés par état (ResStock).	10
2.3	Zones climatiques ASHRAE - distribution, usage chauffage/climatisation et pics de puissance été/hiver (indicateur de flexibilité FlexiMax).	11
2.4	Zone climatique ASHRAE dominante par état.	11
2.5	Distribution (boxplot) de la consommation électrique totale par zone climatique ASHRAE, échantillon de 5 000 bâtiments.	12
3.1	Nombre de bâtiments et consommation moyenne par niveau d'isolation (R-value), plafond / toiture / murs.	13
3.2	Types de chauffage/climatisation et consommation associée ; consommation moyenne par combustible de chauffage.	14
3.3	Consignes de température et potentiel de flexibilité (part des bâtiments avec thermostat programmable).	14
3.4	Présence et localisation des gaines de distribution d'air ; impact des fuites sur la consommation.	14
3.5	Consommation moyenne et intensité (kWh/ft ²) par décennie de construction.	15
3.6	Distribution du nombre d'occupants et consommation moyenne associée.	15
3.7	Décomposition de la consommation électrique moyenne par usage (chauffage, climatisation, eau chaude, électroménager « blanc », électronique « brun »...) et répartition des variables retenues par catégorie métier.	16
3.8	Répartition de la consommation nationale totale (tous vecteurs, ménages pondérés).	17
3.9	Corrélation de Pearson entre les consommations par groupe fonctionnel.	17
5.1	R^2 , RMSE et RMSE relative - modèle multi-cibles pré-recentrage (<code>lightgbm_stratified</code>) vs modèle électricité sur le périmètre tout-électrique (<code>lgbm_electricity</code>).	20
5.2	R^2 et RMSE par usage électrique (total, chauffage, climatisation, eau chaude), jeu de features Physique.	21
5.3	Importance des 83 variables du jeu Physique (gain LightGBM) - les 5 agrégats physiques en rouge.	22
6.1	Les 365 profils horaires bruts d'un bâtiment (347201-0, exemple illustratif), superposés (semaine en bleu, weekend en rouge) - avant toute normalisation ou clustering. Le bâtiment de référence pour l'analyse qui suit (10672-0) est introduit ci-dessous.	23
6.2	Méthode du coude et score de silhouette pour les deux normalisations - bâtiment 10672-0.	24
6.3	Courbes de consommation moyenne par cluster, sur 24h - bâtiment 10672-0.	25
6.4	Décomposition par poste de consommation, profils d'amplitude par cluster - bâtiment 10672-0. Le chauffage (hachures vertes) domine et porte les pics.	26
6.5	Méthode du coude et score de silhouette - clustering multivarié (forme + amplitude + météo) sur les 36 500 jours-bâtiment du panel.	27
6.6	Température extérieure, amplitude relative et répartition semaine/weekend par cluster - 36 500 jours-bâtiment.	27
6.7	Profils de forme moyens par cluster - axe matin/soir visible à l'échelle du panel.	27
6.8	Architecture hybride à deux branches (« two-tower ») - commune aux parties A et B, seuls la fenêtre d'entrée et les tailles de couches différent.	28

6.9	Partie A - prévision $t+1$ (24h) : métriques et résidus.	28
6.10	Partie A - consommation réelle vs prédite, bâtiment de test #41, deux premières semaines. Le modèle suit le rythme journalier mais lisse certains pics.	29
6.11	Partie B - extrapolation annuelle (90j) : métriques et détail par bâtiment.	29
A.1	Profils moyens par cluster en valeurs réelles (kWh), complément à la figure 6.7.	39

Liste des tableaux

1.1	Structure du jeu de métadonnées nettoyé (391 colonnes, 549 971 bâtiments).	7
1.2	Les 11 groupes de variables in.* (549 971 bâtiments).	9
1.3	Les 14 groupes de variables out.* (549 971 bâtiments).	9
4.1	Les 108 attributs in.* encodés dans X.parquet , par groupe métier.	18
4.2	Les 5 agrégats physiques (modèle RC) remplaçant 30 attributs bruts d'enveloppe. . . .	19
A.2	Vue d'ensemble du pipeline de notebooks du dépôt FlexiMax.	39

CHAPITRE 1

Contexte : le stage, FlexiMax et les données

1.1 Le jeu de données ResStock

Le jeu de données central de ce stage est **ResStock 2025 Release 1**, produit par le National Renewable Energy Laboratory (NREL) : une simulation bâtiment par bâtiment du parc résidentiel américain, à partir de modèles EnergyPlus calibrés sur le parc réel (recensement, enquêtes RECS). Le fichier national `upgrade0.parquet` - scénario *baseline*, avant upgrades - couvre 549 971 bâtiments décrits par 771 colonnes.

Ces colonnes se répartissent en deux familles, une distinction qui structure tout le rapport :

- les variables **in.*** (« inputs ») décrivent le bâtiment simulé : localisation, géométrie, enveloppe thermique, système HVAC, appareils, profil socio-économique, ce sont les *features* des modèles prédictifs ;
- les variables **out.*** (« outputs ») sont les résultats de simulation EnergyPlus : consommations par usage et vecteur énergétique (électricité, gaz naturel, propane, fioul), émissions de CO₂e, factures, dimensionnement, heures d'inconfort... Elles fournissent les *cibles* des modèles (`out.electricity.total.energy_consumption..kwh` pour la consommation électrique annuelle) et plusieurs indicateurs de lecture (décomposition par usage, cf. §3.5).

Répartition in.* / out.* - Source : 02_nettoyage/nettoyage_metadata.ipynb

Après nettoyage (§1.2), les 391 colonnes se répartissent en 165 in.*, 221 out.* et 5 colonnes d'identification/pondération.

TABLE 1.1 – Structure du jeu de métadonnées nettoyé (391 colonnes, 549 971 bâtiments).

Famille	Colonnes
in.* - caractéristiques du bâtiment (features)	165
out.* - résultats de simulation (cibles & indicateurs)	221
Identifiants et pondération (bldg_id, weight...)	5

Ce ratio out/in (1,3 sortie par entrée) reflète la richesse des sorties EnergyPlus (décomposition fine par usage et vecteur) face à des entrées plus synthétiques : la difficulté du problème de prédiction ne vient donc pas d'un manque de cibles, mais du choix de la bonne cible parmi les out.* et des bonnes *features* parmi les in.*.

Deux autres sources complètent le jeu ResStock : les séries temporelles individuelles par bâtiment (pas 15 minutes, 35 040 lignes/an, téléchargées depuis l'OEDI via `extraction_timeseries_oedi.ipynb`) et les données météo horaires par zone climatique ASHRAE utilisées par EnergyPlus. Le guide technique ResStock (`ResStockTechnicalReferenceGuide_2025_1.pdf`, dans `reports/figures/`) documente la définition exacte de chaque variable citée dans ce rapport.

Un choix méthodologique à expliciter : FlexiMax est un projet français (MINES Paris - PSL / ARMINES, France 2030 / ADEME), mais aucune base résidentielle française de résolution et de richesse comparable à ResStock n'était disponible pour ce stage, d'où le recours aux données américaines du NREL. Ce choix n'est pas neutre : le parc américain diffère du parc français sur plusieurs dimensions rencontrées au fil de l'analyse - le mix énergétique du chauffage (part du gaz et du fioul bien plus importante aux États-Unis qu'en France), les habitudes de vie et d'occupation, la mobilité (le véhicule électrique et son infrastructure de recharge sont modélisés selon des usages nord-américains) et le parc d'équipements électroménagers (types, tailles, rendements). Les résultats de ce rapport décrivent donc le parc résidentiel *américain* ; leur transposition au contexte français

reste à valider dès que des données comparables seront disponibles.

1.2 Nettoyage des métadonnées

Avant toute exploration, encore faut-il s'assurer que les 771 colonnes brutes sont exploitables :

Source : 02_nettoyage/nettoyage_metadata.ipynb

Le fichier national brut (`upgrade0.parquet`) contient 549 971 bâtiments $\times$ 771 colonnes. 380 colonnes sont supprimées selon 6 critères, pour 391 colonnes conservées :

- `upgrade.*` (20 col.) - toutes vides dans le scénario baseline (`upgrade=0`) ;
- `calc.weighted.*` (172 col.) - agrégats de pondération, non utiles bâtiment par bâtiment ;
- `out.* savings/reduction` (164 col.) - économies vs upgrade, toutes à 0 en baseline ;
- `in.simulation_control.*` (6 col.) - identiques pour tous les bâtiments ;
- `in.utility_bill.*` (8 col.) - déjà présentes sous `out.utility_bills.*` ;
- doublons de colonnes « binned » moins précises que leur équivalent continu (10 col.).

Après nettoyage : 0 colonne entièrement vide, 0 colonne à plus de 50% de valeurs manquantes. Ces suppressions ne traduisent pas un problème de qualité (aucune donnée aberrante ou incomplète) mais des artefacts de la méthodologie ResStock elle-même (répétition du scénario *baseline* dans les colonnes `upgrade.*`/*savings*, doublons d'agrégation) : le jeu nettoyé, exporté vers `data/processed/metadata_clean.parquet`, est donc directement exploitable sans étape d'imputation.




FIGURE 1.1 – Colonnes gardées vs supprimées par groupe (771 $\rightarrow$ 391 colonnes).

1.3 Structure du jeu nettoyé : variables `in.*` et `out.*`

1.3.1 Variables `in.*`

Source : 01_exploration/exploration_in_groups.ipynb

Sur les 391 colonnes du jeu de métadonnées nettoyé, 165 colonnes `in.*` décrivent le bâtiment et ses occupants, réparties en 11 groupes métier (164 colonnes couvertes, seule `in.upgrade_name` reste hors groupe) :

TABLE 1.2 – Les 11 groupes de variables **in.*** (549 971 bâtiments).

Groupe	Colonnes	% manquant moyen
Localisation	21	0,0%
Zone climatique	5	0,0%
Géométrie du bâtiment	20	0,0%
Enveloppe thermique	17	0,0%
HVAC	42	0,0%
Eau chaude	6	0,0%
Appareils électroménagers	28	0,0%
Véhicule électrique	6	0,0%
Panneau électrique	2	0,0%
Solaire et stockage	4	0,0%
Occupants et socio-économique	13	0,9%

Le taux de manquant quasi nul (base *simulée*, pas de non-réponse d'enquête, seul le groupe Occupants en présente 0,9%) évite tout travail d'imputation, un confort rare face à des données réelles de consommation. La richesse du groupe HVAC (42 variables) en fait le principal réservoir de leviers de flexibilité pilotables (thermostats, systèmes), là où enveloppe et géométrie (17+20 variables) ne décrivent que des caractéristiques figées du bâti.

1.3.2 Variables **out.***

Source : 02_nettoyage/nettoyage_metadata.ipynb - calcul direct sur metadata_clean.parquet

Les 221 colonnes **out.*** sont les résultats de simulation EnergyPlus, réparties en 14 groupes, dominés par la consommation électrique (60 col.) et les paramètres physiques dérivés du bâtiment (57 col. - surfaces, dimensionnement, contraintes de panneau électrique) :

TABLE 1.3 – Les 14 groupes de variables **out.*** (549 971 bâtiments).

Groupe	Colonnes	% manquant moyen
Consommation électrique (electricity)	60	0,0%
Paramètres physiques dérivés (params)	57	0,0%
Émissions CO ₂ e (emissions)	33	0,3%
Consommation gaz naturel (natural_gas)	22	0,0%
Consommation propane (propane)	12	0,0%
Consommation fioul (fuel_oil)	8	0,0%
Charges thermiques (load)	7	0,0%
Factures (utility_bills)	5	0,0%
Eau chaude, volumes (hot_water)	4	0,0%
Énergie totale du site (site_energy)	4	0,0%
Puissances dimensionnantes (capacity)	3	0,0%
Heures d'inconfort thermique (unmet_hours)	3	0,0%
Indicateurs de qualité (qoi)	2	0,0%
Taux d'effort énergétique (energy_burden)	1	12,1%

Seule **out.energy_burden..percentage** présente un manquant notable (12,1%, probablement logements vacants ou sans revenu déclaré). Cinq cibles candidates ressortent de ces 221 colonnes, la consommation totale par vecteur énergétique et les émissions associées, mais chaque vecteur a sa propre distribution et ses propres facteurs explicatifs : c'est cette hétérogénéité qui a justifié de n'en retenir qu'une seule, l'électricité, comme cible finale du rapport.

Le jeu de données posé, l'exploration qui suit cherche à identifier lesquelles de ces 165 variables **in.*** pèsent réellement sur la consommation, en partant du facteur le plus immédiat, la géographie, avant d'élargir progressivement aux caractéristiques du bâtiment lui-même (chapitre 3).

CHAPITRE 2

Le climat, premier déterminant de la consommation

2.1 Localisation et zone climatique

Source : `exploration_localisation_climat.ipynb`

La Californie, le Texas et la Floride concentrent le plus de bâtiments simulés, mais ce sont des états au climat plus doux (CA en particulier) qui affichent les consommations moyennes les *plus faibles* du top 20 (8 030 kWh/an) - à l'inverse, le Tennessee (15 887 kWh/an), la Virginie et le Missouri dominent malgré un parc plus petit. Au niveau régional, le Sud regroupe le plus de bâtiments (210 283) et la consommation moyenne la plus élevée ($\sim 14\,400$ kWh/an) ; le Nord-Est est la région la moins consommatrice.




FIGURE 2.1 – Top 20 états par nombre de bâtiments et par consommation électrique moyenne ; consommation moyenne par région Census.




FIGURE 2.2 – Nombre de bâtiments simulés par état (ResStock).

Le nombre de bâtiments simulés ne suit donc pas la consommation : c'est la zone climatique, pas la taille du parc, qui structure ces écarts.

Zone climatique ASHRAE - déterminant n°1 identifié par le modèle prédictif

Les zones 5A (123 952 bâtiments) et 4A (118 416) dominent le parc ; les zones extrêmes (1A « très chaud », 7B/8AK « arctique ») sont marginales (<1 000 bâtiments). Le gradient chauffage/climatisation est net : la 2B très chaude/humide consomme ~6 800 kWh/an de climatisation contre quasiment rien en chauffage, l'inverse pour les zones froides 6A/7A. Le panneau « pics de puissance été/hiver », lu comme indicateur de **flexibilité FlexiMax**, montre des pics hivernaux nettement supérieurs aux pics estivaux pour les zones froides (2A, 3A), et l'inverse pour les zones chaudes (1A, 2B) : le potentiel de flexibilité n'est donc pas uniforme sur le territoire.




FIGURE 2.3 – Zones climatiques ASHRAE - distribution, usage chauffage/climatisation et pics de puissance été/hiver (indicateur de flexibilité FlexiMax).




FIGURE 2.4 – Zone climatique ASHRAE dominante par état.

2.2 Une dispersion que le climat seul n'explique pas

Les moyennes par zone (§2.1) masquent la distribution complète : est-ce que deux bâtiments de la même zone climatique consomment vraiment de façon comparable ?

Source : `visualisation_metadata.ipynb` - échantillon illustratif de 5 000 bâtiments

Vue complémentaire, en distribution complète plutôt qu'en moyenne, de la consommation électrique par zone climatique : les zones les plus peuplées (4A, 5A) présentent aussi la plus grande dispersion et les valeurs extrêmes les plus hautes (jusqu'à ~90 000 kWh/an en zone 7A), ce que les moyennes seules (§2.1) ne laissaient pas apparaître. Cette dispersion intra-zone confirme que la zone climatique, quoique déterminante, n'explique pas tout : d'autres facteurs bâtimentaires et comportementaux restent nécessaires pour capturer les extrêmes.




FIGURE 2.5 – Distribution (boxplot) de la consommation électrique totale par zone climatique ASHRAE, échantillon de 5 000 bâtiments.

Reste donc à identifier ce qui, à zone climatique égale, distingue un bâtiment qui consomme peu d'un bâtiment qui consomme beaucoup : le bâti, les systèmes techniques et le comportement des occupants, explorés au chapitre 3.

CHAPITRE 3

Au-delà du climat : bâti, équipements et comportement

Ce chapitre couvre les trois familles de déterminants encore non explorées - l'enveloppe thermique, les systèmes techniques (HVAC, eau chaude), et le profil des occupants - avant de les synthétiser en une classification métier et une lecture par usage et par vecteur énergétique.

3.1 Enveloppe thermique

Source : `exploration_enveloppe_thermique.ipynb`

Pour le plafond et la toiture, la relation isolation $\rightarrow$ consommation suit la logique attendue : la consommation moyenne diminue quand le R-value augmente (plafond non isolé $\approx 16\,500$ kWh vs R-49 $\approx 13\,200$ kWh). Pour les murs en revanche, la relation n'est *pas* monotone (R-15 associé à une consommation plus élevée que R-11 ou R-19) : signe probable d'un facteur de confusion non contrôlé (l'isolation des murs est corrélée à la zone climatique et au type de bâtiment). Une lecture « toutes choses égales par ailleurs » nécessiterait de contrôler ces facteurs (régression multivariée, comparaison à zone climatique fixée).




FIGURE 3.1 – Nombre de bâtiments et consommation moyenne par niveau d'isolation (R-value), plafond / toiture / murs.

3.2 Système HVAC

Source : `exploration_hvac.ipynb`

Types de systèmes. La pompe à chaleur gainée (*Ducted Heat Pump*) affiche la consommation électrique moyenne la plus élevée (15 845 kWh/an), devant le chauffage gainé classique (11 458) et non gainé (9 847). Côté climatisation, le *Central AC* domine en nombre (291 239 bâtiments) devant le *Room AC* (108 992). Par combustible, le chauffage électrique a la consommation électrique moyenne la plus élevée (15 564 kWh/an), loin devant gaz/propane/fioul ($\sim 9\,000$ kWh/an).

Consignes de température (flexibilité FlexiMax). Consigne médiane 70°F (chauffage), 72°F (climatisation). 43,8% des bâtiments ont un thermostat programmable pour le chauffage, 35,8% pour la climatisation : une majorité n'a donc *pas* de pilotage automatique, ce qui borne le potentiel de flexibilité activable sans changement d'équipement.

Gaines (ducts). 423 599 bâtiments sur $\sim 550\,000$ ont des gaines de distribution d'air, avec une consommation moyenne nettement supérieure (12 772 kWh/an) à ceux qui n'en ont pas (8 348 kWh/an) - surtout un effet de taille/type de système (gaines associées aux systèmes centraux, plus consommateurs). Les fuites de gaines sont associées à une surconsommation croissante avec le taux de fuite, à isolation égale.

3.3 Occupants et profil socio-économique




FIGURE 3.2 – Types de chauffage/climatisation et consommation associée; consommation moyenne par combustible de chauffage.




FIGURE 3.3 – Consignes de température et potentiel de flexibilité (part des bâtiments avec thermostat programmable).




FIGURE 3.4 – Présence et localisation des gaines de distribution d'air; impact des fuites sur la consommation.

Source : `exploration_occupants.ipynb`

Sur le *vintage* du bâti, un paradoxe apparent : plus un bâtiment est récent, plus sa consommation *absolue* est élevée (10 013 kWh/an avant 1940 à 12 659 kWh/an années 2000), alors que l'*intensité* (kWh/ft²) est minimale pour les années 2010 (7,0 kWh/ft²) - les constructions récentes sont plus efficaces par m², mais en moyenne plus grandes. Côté occupants, la relation est quasi linéaire avec la consommation moyenne : de ~4 100 kWh/an à 0 occupant (vacant) à ~21 700 kWh/an à 9 occupants. Les foyers de 2 personnes dominent (167 006 bâtiments), suivis des foyers d'une personne (132 575).

3.4 Classification métier des variables

Enveloppe, HVAC, occupants : ces familles explorées séparément gagnent à être mises en regard des usages électriques eux-mêmes, pour juger lesquelles sont réellement pilotables.

Source : `03_visualisation/classification_variables.ipynb`

Ce notebook croise les 165 variables `in.*` avec les usages électriques `out.electricity.*` pour produire une classification « métier » (plutôt que technique), utilisée comme grille de lecture pour la suite du rapport :

- **61** variables retenues (Enveloppe 33%, HVAC 16%, Socio-économique 11%, Météo/climat 10%, Comportemental 9%, Eau chaude 6%, Occupants/VE/PV 5% chacun), **16** écartées (redondantes ou non pilotables) ;



FIGURE 3.5 – Consommation moyenne et intensité (kWh/ft²) par décennie de construction.

FIGURE 3.6 – Distribution du nombre d'occupants et consommation moyenne associée.

- Décomposition de la *consommation électrique* moyenne (11 756 kWh/an, tous usages électriques confondus) : climatisation (27,4%), électronique « brun » (20,6%), chauffage (19,3%), électroménager « blanc » (14,5%), eau chaude (8,2%), éclairage (7,5%), divers (1,9%) - climatisation et chauffage électriques combinés (46,7% *de l'électricité*) restent le premier poste, mais l'écart avec l'« électronique brun » (non pilotable, 20,6%) borne le gain maximal atteignable par la seule flexibilité thermique. À ne pas confondre avec la part du confort thermique tous vecteurs confondus (64,2%, §3.5) : cette dernière inclut aussi le chauffage au gaz, propane et fioul, absent ici ;
- Cas *in.neighbors* : pas un proxy météo mais une variable de mitoyenneté (67,7% de maisons individuelles), gardée comme feature d'enveloppe plutôt qu'écartée comme redondante ;
- VE : 1,1% des ménages seulement, mais consommation de recharge moyenne de 2 082 kWh/an (contre 22 kWh/an sur l'ensemble du parc) - marginal en pénétration mais fortement pilotable, à traiter séparément de l'analyse thermique.

Cette classification par catégorie, plutôt qu'une liste plate de 61 variables, servira de grille de lecture pour l'importance des variables du futur modèle prédictif : elle permettra de juger si un déterminant dominant relève du bâti, du climat ou du comportement, plutôt que d'interpréter chaque variable isolément.

Schéma hiérarchique - consommation électrique et facteurs explicatifs

CONSUMATION ELECTRIQUE RESIDENTIELLE

+++ Chauffage	-> out.electricity.heating.*	Pilotable (thermostat)
+++ Climatisation	-> out.electricity.cooling.*	Pilotable (setpoint offset)
+++ Eau chaude (DHW)	-> out.electricity.hot_water.*	Pilotable (heure de chauffe)
+++ Eclairage	-> out.electricity.lighting_* + ceiling_fan	Pilotable partiel
+++ Ventilation	-> out.electricity.mech_vent	Pilotable partiel
+++ Usages spécifiques		
+++ Blanc (electromenager) :	lave-linge, seche-linge, lave-vaisselle,	
refrigerateur, congelateur, cuisiniere		Pilotable partiel (horaires decalables)




FIGURE 3.7 – Décomposition de la consommation électrique moyenne par usage (chauffage, climatisation, eau chaude, électroménager « blanc », électronique « brun »...) et répartition des variables retenues par catégorie métier.

```
|      +-- Brun (electronique) : television, plug_loads          Non pilotable
+-- VE (traitement separe) -> ev_charging                      Pilotable (recharge decalable)

FACTEURS EXPLICATIFS
+-- Occupants          in.occupants, in.usage_level, in.vacancy_status
+-- Comportement       in.heating_setpoint*, in.cooling_setpoint*, in.*_usage_level
+-- Meteo (proxys)     in.ashrae_iecc_climate_zone_2004, in.weather_file_latitude/longitude
+-- Enveloppe thermique in.insulation_*, in.air_leakage_*, in.windows, in.geometry_*, in.neighbors
+-- HVAC               in.hvac_heating_type, in.hvac_cooling_type, in.hvac_*_efficiency
+-- Socio-economique   in.income, in.federal_poverty_level, in.tenure, in.area_median_income
```

3.5 Décomposition nationale par usage et par vecteur énergétique


La classification précédente porte sur l'électricité seule. Élargie à *tous* les vecteurs énergétiques (gaz, propane, fioul inclus), la même décomposition par usage change-t-elle d'équilibre ?

Source : 03_visualisation/visual.ipynb - upgrade0.parquet - ménages pondérés

Sur le parc entier (549 971 bâtiments pondérés), le confort thermique (chauffage + climatisation, *tous vecteurs*) concentre **64,2%** de la consommation totale, loin devant l'eau chaude sanitaire (12,0%) et le divertissement/loisirs (11,3%). Ce chiffre est plus élevé que les 46,7% mesurés pour l'électricité seule (§3.4) : l'écart est le gaz, le propane et le fioul consacrés au chauffage, invisibles dans une lecture électricité-only. Par vecteur, l'électricité (1 641,5 TWh) et le gaz naturel (1 479,1 TWh) sont proches en volume national, très loin devant le fioul (178,8 TWh) et le propane (154,1 TWh). La décomposition par groupe montre où se concentre ce gaz : quasi exclusivement sur le confort thermique et, dans une moindre mesure, l'eau chaude sanitaire et l'alimentation - tous les autres usages (divertissement, éclairage, VE, infrastructure, PV) sont déjà quasi 100% électriques. Cette proximité électricité/gaz, concentrée sur les usages thermiques, confirme à l'échelle nationale l'intérêt du recentrage tout-électrique du périmètre.

Corrélations entre usages - 03_visualisation/visual.ipynb

Deux logiques se distinguent. Un **cluster** « **comportemental** » (eau chaude sanitaire, hygiène/nettoyage, divertissement) est fortement corrélé en interne ($\rho = 0,50$ à $0,62$) : ces usages suivent l'intensité d'occupation du logement. Le **confort thermique**, pourtant premier poste (64,2%), n'est que faiblement corrélé aux autres ($\rho = 0,21$ à $0,35$) - sa variance dépend du bâti et du climat, pas du comportement, cohérent avec le rôle de la zone climatique comme déterminant n°1 (§2.1). VE et PV sont quasi indépendants de tout le reste ($|\rho| < 0,05$) : des choix d'équipement, pas de comportement. *Utilité* : un seul proxy d'occupation suffira à résumer le cluster comportemental en feature engineering (§4.1), alors que confort thermique, VE et PV garderont chacun leurs propres variables et leviers de flexibilité dédiés.



(a) Par usage fonctionnel. (b) Par groupe et par vecteur énergétique.

FIGURE 3.8 – Répartition de la consommation nationale totale (tous vecteurs, ménages pondérés).




FIGURE 3.9 – Corrélation de Pearson entre les consommations par groupe fonctionnel.

CHAPITRE 4

De la donnée brute à la feature physique

Ce chapitre transforme les variables `in.*` encodées jusqu'ici en catégories ResStock en un jeu de features numériques, à partir des notebooks `transformations_numeriques.ipynb` et `encodage_categoriel.ipynb`.

4.1 Principe d'encodage

Source : `transformations_numeriques.ipynb` + `encodage_categoriel.ipynb`

Chaque variable `in.*` est encodée selon sa nature : valeur numérique conservée telle quelle, table de correspondance officielle du *ResStock Technical Reference Guide* (isolation, vitrage), extraction de la valeur numérique dans une chaîne composite (ex. cote SEER, EF, IMEF, CEF), encodage binaire ou one-hot pour les catégories nominales sans ordre, et encodage circulaire (sinus/cosinus) pour l'orientation, une variable cyclique ($0^\circ=360^\circ$) qu'un simple entier briserait artificiellement en deux extrêmes opposés.

Cas notable : l'isolation est encodée par sa **valeur R d'assemblage** (celle réellement utilisée par EnergyPlus, incluant les ponts thermiques de l'ossature, Table 45 du guide) plutôt que sa valeur R **nominale** (celle affichée sur le produit) - l'écart croît avec la conductivité de la structure porteuse : un mur à ossature bois isolé R-11 (nominal) descend à 10,3 en valeur d'assemblage, R-15 à 12,1. Un encodage sur la seule valeur nominale surestimerait donc la performance thermique réelle des parois.

Sept variables sont supprimées car constantes sur tout le parc (`in.interior_shading`, `overhangs`, `eaves`, `doors`, `radiant_barrier`, `infiltration`, `door_area`) : une variance nulle ne porte aucune information exploitable, quel que soit l'encodage choisi.

TABLE 4.1 – Les 108 attributs `in.*` encodés dans `X.parquet`, par groupe métier.

Groupe	Var.	Encodage principal appliqué
1 Socio-économique	7	Midpoint d'intervalle (\$), ratio, binaire
2 Occupants	6	Numérique, binaire, label ordinal
3 Météo	2	Numérique (latitude/longitude, inchangé)
4 Enveloppe thermique	32	Lookup R d'assemblage, OHE finitions, circulaire orientation
5 Systèmes HVAC/DHW	25	Conversion °F→°C, extraction SEER/EF, OHE techno./combustible
6 Usages électriques	25	Extraction CEF/EF, binaire présence, OHE énergie
7 Blanc/Brun	4	Ratio (%→décimal), numérique
8 Infrastructure électrique	2	Numérique (A, count - inchangé)
9 Photovoltaïque (PV)	2	Binaire, extraction puissance (kW)
10 Mobilité (VE)	3	Numérique, label niveau de chargeur
Total	108	

Le groupe Enveloppe (32 variables, 30% du total) domine largement : c'est ce volume, et sa spécificité au parc états-unien (catégories ResStock plutôt que grandeurs physiques directes), qui motive l'agrégation du §4.2.

4.2 Agrégation physique de l'enveloppe

Source : 05_deeplearning/lgbm_electricity_5features.ipynb - sous-ensemble tout-électrique plain-pied - 64 062 logements

Pour une variante physiquement interprétable du modèle prédictif (05_deeplearning), un sous-ensemble filtré (maisons individuelles à un niveau, chauffage électrique, sans VE ni piscine ni PV - une restriction plus étroite que le recentrage tout-électrique du rapport) recalcule, à partir des colonnes `out.params.*` et des variables encodées au §4.1, 30 attributs bruts d'enveloppe en **5 grandeurs physiques universelles** :

TABLE 4.2 – Les 5 agrégats physiques (modèle RC) remplaçant 30 attributs bruts d'enveloppe.

Agrégat	Formule (résumée)	Rôle physique
UA (W/K)	$\sum_i U(R_i)A_i + U_{\text{fen}}A_{\text{fen}} + 1,14 A_{\text{porte}}$	Pertes par transmission (murs, toit, plancher, fenêtres, portes)
H_{ve} (W/K)	$0,34 (ACH50/20) V$	Pertes par renouvellement d'air / infiltration
C (kJ/K)	$C_{\text{classe}} \times A_{\text{pl}}$, classes ISO 13790 $\in \{110, 165, 260, 370\}$	Inertie thermique, selon matériau structurel
A_{solaire} (m ²)	$SHGC \times 0,9 \times \sum A_{\text{fen}} \times p(\theta)$, Sud>Est/Ouest>Nord	Gains solaires équivalents
compacité (m ⁻¹)	$(A_{\text{mur}} + A_{\text{toit}} + A_{\text{pl}} + A_{\text{fen}} + A_{\text{porte}})/V$	Coefficient de forme (compacité du bâti)

Bilan : 108 attributs bruts $\rightarrow$ 83 features (5 agrégats physiques + 78 conservés tels quels). Seul le bloc enveloppe (30 attributs) est fondu dans les agrégats ; le reste - HVAC, gaines, eau chaude, occupants, socio-économique, usages électriques - est conservé sans élagage supplémentaire à ce stade. Réduire une trentaine de catégories propres au parc états-unien à cinq grandeurs physiques sert un double objectif : la **transférabilité** - ces grandeurs ont un sens hors ResStock, sur un parc de logements différent - et l'**interprétabilité**, en vue d'un modèle thermique de type RC (résistance-capacité) plutôt qu'une boîte noire sur 108 colonnes hétérogènes. L'importance de ces agrégats dans le modèle prédictif est vérifiée au chapitre 5.

Le détail complet des 108 attributs - variable par variable, avec statut réel (conservé, supprimé ou fondu dans un agrégat) - est reporté en annexe A.1 pour ne pas alourdir ce chapitre.

CHAPITRE 5

Modélisation

Le climat structure la consommation (chapitre 2), l’enveloppe et les équipements expliquent une partie de la dispersion résiduelle (chapitre 3), et 108 attributs bruts ont été réduits à un jeu de features exploitable, physique ou complet (chapitre 4). Ce chapitre vérifie si un modèle prédictif retrouve effectivement ces déterminants, et jusqu’à quel point il peut prédire la consommation électrique.

5.1 Un modèle LightGBM sur le périmètre tout-électrique

Source : 05_deeplearning/lgbm_electricity.ipynb - sous-ensemble tout-électrique plain-pied - 64 062 logements

Un LightGBM entraîné sur les 107 features encodées (§4.1), avec split stratifié par zone ASH-RAE (Train 40 999 / Val 10 250 / Test 12 813) et 50 essais d’optimisation Optuna, atteint sur le test $R^2 = 0,9254$ (RMSE = 2 712 kWh, soit 13,8% de la consommation moyenne; écart train/-test = 0,057, contrôlé). C’est une nette amélioration par rapport au premier modèle du stage, entraîné avant le recentrage tout-électrique sur les 549 971 bâtiments et les cinq vecteurs énergétiques (lightgbm_stratified.ipynb, $R^2 = 0,8446$, RMSE = 28,9%) : le gain (+0,08 de R^2 , RMSE relative divisée par deux) tient moins à un modèle différent qu’au périmètre lui-même - un sous-ensemble tout-électrique et géométriquement homogène, sur une cible unique, stratifié directement sur la zone climatique plutôt que sur une stratification composite plus généraliste.




FIGURE 5.1 — R^2 , RMSE et RMSE relative - modèle multi-cibles pré-recentrage (lightgbm_stratified) vs modèle électricité sur le périmètre tout-électrique (lgbm_electricity).

L’erreur par zone climatique (test) confirme le fil conducteur du rapport : les zones rares et extrêmes (7B, $n = 8$, RMSE = 9 044 kWh ; 6A, $n = 233$, RMSE = 4 168 kWh) concentrent l’essentiel de l’erreur et du biais, tandis que les zones tempérées majoritaires (2A, 3A, 4A) restent sous 3 300 kWh de RMSE, une limite de taille d’échantillon plus qu’une faiblesse du modèle.

5.2 Global vs Physique : le compromis interprétabilité

Source : 05_deeplearning/lgbm_electricity_5features.ipynb - même sous-ensemble - 64 062 logements

Remplacer les 30 attributs bruts d’enveloppe par les 5 agrégats physiques du §4.2 (83 features au lieu de 107, jeu « Physique ») coûte peu : $R^2 = 0,9120$ (RMSE = 2 945 kWh, 15,0%) contre 0,9254 pour le jeu « Global » - une perte de 1,3 point de R^2 pour cinq variables interprétables en moins de description physique du bâti. L’importance des variables confirme que cette perte est mesurée, pas accidentelle : UA arrive en 2^e position (8,85% de l’importance totale, juste derrière la latitude météo), et les 5 agrégats cumulés pèsent **32,3%** de l’importance du modèle - l’enveloppe compte, même réduite à cinq nombres. La latitude et la longitude météo dominent toujours largement (18,4% cumulés), confirmant à l’échelle du modèle prédictif ce que l’exploration suggérait déjà

(§2.1) : le climat prime sur le bâti. Une courbe du coude sur le nombre de features retenues montre par ailleurs que la moitié des attributs (50 sur 83, ou 80 sur 107 pour le jeu Global) suffit à retrouver la performance du jeu complet - la longue traîne de variables à faible importance (VE, PV, spa, piscine, redondantes avec le filtre du sous-ensemble) n'apporte rien de plus.

5.3 Performance par usage électrique

Source : 05_deeplearning/lgbm_electricity_5features.ipynb - quatre modèles - mêmes features et split

Prédire chaque usage séparément (mêmes 83 features, mêmes hyperparamètres qu'en §5.2) révèle une hétérogénéité nette : l'eau chaude sanitaire est l'usage le plus facile ($R^2 = 0,980$, RMSE = 214 kWh) et le chauffage le plus difficile ($R^2 = 0,816$, RMSE relative = 54,0%). Ce n'est pas un défaut du modèle mais une conséquence de la variance du signal : la consommation de chauffage varie fortement d'un ménage à l'autre (moyenne 6 030 kWh, mais 98,9% des logements seulement en ont - contre 84,6% pour l'eau chaude, dont la consommation moyenne, plus faible et plus stable, est mécaniquement plus facile à approcher en valeur relative). La climatisation se situe entre les deux ($R^2 = 0,930$, 18,9%). Ce classement, eau chaude > climatisation > total > chauffage, est cohérent avec le rôle du climat déjà établi : le chauffage est l'usage le plus exposé à la variabilité climatique inter-zones, donc le plus dur à généraliser sur un modèle unique.




FIGURE 5.2 – R^2 et RMSE par usage électrique (total, chauffage, climatisation, eau chaude), jeu de features Physique.




FIGURE 5.3 – Importance des 83 variables du jeu Physique (gain LightGBM) - les 5 agrégats physiques en rouge.

CHAPITRE 6

Dynamique temporelle

Les chapitres précédents traitent la consommation électrique comme une grandeur annuelle : un seul nombre par logement, expliqué par le climat, le bâti et les équipements (chapitres 2 à 5). Or l'électricité qui compte pour la flexibilité se joue à l'heure, pas à l'année. Ce chapitre explore la dimension temporelle sur le même périmètre tout-électrique : d'abord en cherchant des « jours types » par clustering non supervisé des profils journaliers, à l'échelle d'un bâtiment puis d'un panel de 100 bâtiments, puis en entraînant un modèle hybride RNN+MLP pour prédire la consommation à deux horizons (l'heure suivante, et le total annuel à partir de 90 jours observés).

6.1 Jours types : clustering du profil journalier d'un bâtiment de référence

Avant tout traitement, les profils journaliers bruts d'un bâtiment sur une année entière (figure 6.1) ne montrent aucune structure évidente à l'œil nu : c'est précisément ce que le clustering non supervisé qui suit cherche à organiser en régimes identifiables.




FIGURE 6.1 – Les 365 profils horaires bruts d'un bâtiment (347201-0, exemple illustratif), superposés (semaine en bleu, weekend en rouge) - avant toute normalisation ou clustering. Le bâtiment de référence pour l'analyse qui suit (10672-0) est introduit ci-dessous.

Source : 06_timeseries/timeseries_clustering.ipynb - bâtiment 10672-0 - pas 15 minutes


Chaque journée (pas 15 minutes, 96 valeurs $x_1, \dots, x_{96}$) est normalisée de deux façons concurrentes, qui ne portent pas sur le même axe de la matrice jours×pas de temps.

Forme - z-score *intra-jour* (par *ligne*) : pour un jour j donné, $x_{j,i}^{\text{forme}} = (x_{j,i} - \bar{x}_j) / \sigma_j$, où $\bar{x}_j$ et σ_j sont la moyenne et l'écart-type calculés sur les 96 valeurs de *ce jour* uniquement. Chaque jour est donc recentré-réduit sur sa propre échelle : le niveau absolu disparaît complètement, seule reste la position relative des pics et des creux dans la journée.

Amplitude - **StandardScaler global** (par *colonne*) : pour un pas de temps i (une heure de la journée) donné, $x_{j,i}^{\text{amplitude}} = (x_{j,i} - \bar{x}_i) / \sigma_i$, où $\bar{x}_i$ et σ_i sont cette fois calculés sur *ce même pas de temps*, à travers *tous* les jours de l'année. La consommation de 8h un jour donné est donc comparée

à la consommation moyenne à 8h sur l'année entière : les écarts de niveau global entre un jour creux et un jour très consommateur sont *préservés*, contrairement à la forme.

Un K-Means est ajusté séparément sur chaque représentation, avec k choisi par méthode du coude puis vérifié par score de silhouette. Les deux normalisations retiennent toutes deux $k = 5$, mais avec des profils de silhouette très différents : la forme culmine à $k = 3$ (0,29) puis décroît (0,21 à $k = 5$) - des tailles de cluster 46/79/129/71/40, avec un recouvrement net entre formes voisines ; l'amplitude culmine dès $k = 2$ (0,56) et reste élevée à $k = 5$ (0,39, tailles 24/231/11/70/29) - un clustering nettement mieux séparé, porté par un cluster majoritaire (231 jours, le régime courant) entouré de clusters minoritaires qui captent les jours extrêmes.



(a) Forme - $k = 5$ retenu, silhouette maximale 0,29 (à $k = 3$).

(b) Amplitude - $k = 5$ retenu, silhouette maximale 0,56 (à $k = 2$).

FIGURE 6.2 – Méthode du coude et score de silhouette pour les deux normalisations - bâtiment 10672-0.

La figure 6.2 rend visible l'écart entre les deux normalisations : le score de silhouette de l'amplitude reste au-dessus de 0,29 sur toute la plage $k = 2$ à $k = 9$, contre un plafond à 0,29 (atteint une seule fois, à $k = 3$) puis une chute continue pour la forme - un clustering objectivement plus net, cohérent avec le diagnostic du texte ci-dessus.


Les courbes de la figure 6.3 donnent un visage concret aux clusters : pour l'amplitude, le cluster majoritaire (1, $n = 231$) reste plat et bas toute la journée, tandis que les clusters minoritaires (0, 2, 3, 4) affichent des niveaux et des pics (vers 12h et 22h) nettement plus marqués - une différence de *palier*, pas de forme. Pour la forme, les 5 courbes se chevauchent visiblement sur la journée, avec des pics communs à 11-12h et 21-22h dont seule l'amplitude relative diffère, ce chevauchement visuel est la contrepartie directe de la silhouette faible mesurée plus haut.

La composition calendaire des clusters de forme confirme un résultat plus riche qu'une simple opposition saison/semaine : les clusters 1 ($n = 79$) et 4 ($n = 40$) sont tous deux concentrés en hiver (novembre-février), mais s'opposent presque parfaitement sur le rythme hebdomadaire - 100% de jours de semaine pour le cluster 1, 77,5% de weekend pour le cluster 4. À l'inverse, les clusters 0 ($n = 46$) et 2 ($n = 129$) se recoupent sur la saison estivale (mai-septembre) sans opposition semaine/weekend marquée. Le climat (chapitre 2) structure donc bien la forme du profil journalier, mais le rythme hebdomadaire s'y superpose - les deux facteurs n'agissent pas au même niveau, la saison fixant le *régime* et la semaine modulant son *occurrence*.

Source : 06_timeseries/timeseries_clustering.ipynb - décomposition par poste - bâtiment 10672-0

Les métadonnées statiques du foyer (revenu 15 000–19 999\$, sous le seuil de pauvreté fédéral ; 3 occupants ; locataire ; bâtiment des années 1950 ; chauffage gainé, climatisation centrale) ne disent rien de *quand* la consommation varie dans la journée, elles ne portent aucune information temporelle. La décomposition par poste, elle, est directe : le **chauffage** domine presque entièrement chaque courbe et porte, à lui seul, les deux pics à 11–12h et 21–22h sur les clusters d'hiver (0, 2, 3, 4 en amplitude) - les autres postes (eau chaude, réfrigérateur, éclairage) restent une fine bande quasi plate en comparaison. Le cluster majoritaire (amplitude, $n = 231$) est quasiment plat toute la journée précisément parce que le chauffage y est quasi nul, des journées assez douces pour ne pas en avoir besoin. Ce motif à deux pics quotidiens est cohérent avec la métadonnée `in.heating_setpoint_has_offset = Yes` : ce foyer dispose d'un thermostat programmable pour le chauffage, et le double pic correspond au cycle classique d'abaissement/relance (nuit puis journée d'absence, relance le matin et en début de soirée) plutôt qu'à un usage continu.

10672-0 — Profil journalier par rapport à la forme d'énergie consommée (k=5)

(a) Forme - profils normalisés par cluster (moyenne $\pm$ écart-type).

10672-0 — Profil journalier par rapport à la quantité d'énergie consommée (k=5)


(b) Amplitude - profils en kWh par cluster (moyenne $\pm$ écart-type).

FIGURE 6.3 – Courbes de consommation moyenne par cluster, sur 24h - bâtiment 10672-0.




FIGURE 6.4 – Décomposition par poste de consommation, profils d'amplitude par cluster - bâtiment 10672-0. Le chauffage (hachures vertes) domine et porte les pics.

6.2 Vers un clustering à l'échelle du panel

Source : 06_timeseries/timeseries_clustering_multi.ipynb - 100 bâtiments tout-électriques - 36 500 jours-bâtiment

Passer du bâtiment unique au panel change l'échelle : 100 bâtiments tout-électriques (même filtre que les chapitres 5, plain-pied et sans équipement électrifiable annexe) téléchargés en séries horaires (8 760 h/an chacun), soit 36 500 jours-bâtiment. Chaque jour est décrit par sa forme (réduite par PCA sur 10 composantes - la première capte 38% de la variance de forme sur l'ensemble du panel, 80% cumulés sur les 10, signe d'une diversité de formes journalières plutôt que d'un mode unique dominant), son amplitude et 12 variables météo (moyenne/min/max de température, humidité relative, température humide, ratio d'humidité), soit 23 dimensions au total. Passer à plusieurs bâtiments impose de changer la normalisation de l'amplitude : le `StandardScaler` global suffisant au §6.1 (un seul bâtiment) séparerait ici surtout les « gros » logements des « petits », pas les jours atypiques d'un jour ordinaire *pour un bâtiment donné*. L'amplitude est donc transformée en $\log(1 + x)$ puis centrée-réduite *par bâtiment* (moyenne et écart-type calculés sur les 365 jours de chaque logement pris individuellement, pas sur l'ensemble du panel) - un jour à $z = +1$ signifie « journée inhabituellement chargée pour ce logement », quelle que soit sa taille. La météo, elle, reste standardisée globalement (pas de log, pas de centrage par bâtiment) pour rester directement interprétable dans les corrélations qui suivent. La méthode du coude retient $k = 6$, mais le score de silhouette culmine nettement à $k = 2$ (0,33) puis décroît de façon quasi monotone jusqu'à $\sim 0,10$ - un signal ambigu, plus caractéristique d'un continuum de comportements que de régimes bien séparés que de 6 régimes nettement tranchés. Le clustering final ($k = 6$) reste néanmoins interprétable : tailles 5 210 / 4 867 / 12 526 / 5 280 / 4 327 / 4 290 jours, **aucun bâtiment ne dépasse $\sim 4\%$ d'un cluster donné** (vérifié par validation croisée bâtiment $\times$ cluster) - les régimes trouvés sont bien des comportements partagés à l'échelle du parc, pas des identités de bâtiments recyclées.

Source : 06_timeseries/timeseries_clustering_multi.ipynb - clustering multivarié final - 36 500 jours-bâtiment

La température extérieure moyenne sépare nettement les 6 clusters (1,8°C à 25,4°C de médiane) et son lien avec l'amplitude relative (z-score par bâtiment) est directement lisible : les deux clusters les plus froids (3 : 1,8°C ; 5 : 3,8°C) portent l'amplitude la plus élevée (+1,1 et +0,8), les deux plus tempérés (0 : 20,1°C ; 4 : 15,2°C) l'amplitude la plus basse (-0,8 et -1,0) - un lien quasi monotone froid $\rightarrow$ surconsommation qui confirme, à l'échelle du panel, le rôle du chauffage déjà identifié au §6.1 sur un seul bâtiment. Le cluster majoritaire (2, $n = 12 526$, 34% des jours) est le plus chaud




FIGURE 6.5 – Méthode du coude et score de silhouette - clustering multivarié (forme + amplitude + météo) sur les 36 500 jours-bâtiment du panel.

(25,4°C) mais reste proche de l'amplitude moyenne ($-0,1$), la climatisation ne crée pas le même effet de surconsommation marquée que le chauffage sur ce périmètre tout-électrique. La répartition semaine/weekend, elle, reste uniforme sur tous les clusters (69–76% de jours de semaine, proche du ratio naturel 5/7) - comme au §6.1, le climat structure ces régimes, pas le rythme hebdomadaire. Les profils de forme moyens par cluster révèlent un second axe de variation, orthogonal à l'amplitude : certains clusters (1, 3) culminent tôt (pic vers 6–8h puis déclin), d'autres (2, majoritaire) culminent tard (pic vers 16–17h), un axe *matin vs soir* qui n'apparaît pas dans l'analyse mono-bâtiment du §6.1 et qui n'est visible qu'à l'échelle du panel, où la composante principale de forme (38% de variance, la plus forte des 10 composantes) capture ce décalage de phase plutôt qu'une simple différence d'intensité.




FIGURE 6.6 – Température extérieure, amplitude relative et répartition semaine/weekend par cluster - 36 500 jours-bâtiment.




FIGURE 6.7 – Profils de forme moyens par cluster - axe matin/soir visible à l'échelle du panel.

6.3 Un modèle hybride RNN+MLP pour deux horizons de prédiction

Source : 06_timeseries/rnn_mlp_hybrid_electricite.ipynb - 100 bâtiments tout-électriques - architecture GRU+MLP à deux branches

L'architecture combine une branche séquentielle (GRU, qui encode une fenêtre de consommation et météo passées) et une branche statique (MLP, qui encode les métadonnées physiques du bâtiment - dont les 5 agrégats d'enveloppe du §4.2), concaténées avant une tête de régression commune (figure 6.8). Le split train/val/test (70/15/15) se fait *par bâtiment*, pas par fenêtre temporelle : le modèle est testé sur des bâtiments jamais vus, condition plus proche d'un usage en diagnostic énergétique qu'un split temporel intra-bâtiment. La même architecture sert aux deux parties ; seuls la longueur de fenêtre, la taille du GRU et le dropout changent (précisés ci-dessous).




FIGURE 6.8 – Architecture hybride à deux branches (« two-tower ») - commune aux parties A et B, seuls la fenêtre d'entrée et les tailles de couches diffèrent.

Source : 06_timeseries/rnn_mlp_hybrid_electricite.ipynb - Partie A - prévision à $t+1$

Avec une fenêtre de 24h, 611 520 fenêtres d'entraînement (70 bâtiments $\times$ 8 736 fenêtres) et un GRU à 32 unités, le modèle hybride bat la baseline de persistance (dernière heure observée) : $R^2 = 0,877$ contre 0,827, RMSE = 1,00 kWh contre 1,19 kWh (-16%). Le gain est net mais mesuré : la persistance est déjà un concurrent sérieux à l'échelle horaire, la dynamique de consommation étant fortement autocorrélée d'une heure à l'autre. Les résidus sont centrés sur zéro mais asymétriques : le modèle a tendance à *sous-estimer* les pointes de consommation les plus fortes (queue négative visible au-delà de 10 kWh réels), pas à les sur-estimer - un biais prudent, cohérent avec une tête de régression qui moyenne les régimes plutôt que de traquer les extrêmes rares.




FIGURE 6.9 – Partie A - prévision $t+1$ (24h) : métriques et résidus.






FIGURE 6.10 – Partie A - consommation réelle vs prédite, bâtiment de test #41, deux premières semaines. Le modèle suit le rythme journalier mais lisse certains pics.

Source : 06_timeseries/rnn_mlp_hybrid_electricite.ipynb - Partie B - extrapolation annuelle

À partir des 90 premiers jours observés, avec seulement 70 exemples d'entraînement (une observation par bâtiment) et un réseau volontairement réduit (GRU 16 unités, dropout 0,3), le modèle hybride explique $R^2 = 0,803$ de la variance du total annuel (RMSE = 5 607 kWh contre 12 637 kWh pour une baseline naïve - la moyenne du train, -56%). Le signal est réel mais évalué sur seulement 15 bâtiments de test : à confirmer sur un panel plus large avant toute conclusion définitive, comme le note explicitement le notebook source. Le détail par bâtiment confirme cette prudence : la prédiction suit bien le classement des logements du moins au plus consommateur, mais le bâtiment le plus extrême du test (55 500 kWh réels) est nettement sous-estimé (~40 000 kWh prédits) - avec seulement 70 exemples d'entraînement, le modèle n'a simplement pas vu assez de cas aussi extrêmes pour bien les extrapoler.



(a) RMSE / MAE vs baseline naïve.



(b) Réel vs prédit par bâtiment de test.

FIGURE 6.11 – Partie B - extrapolation annuelle (90j) : métriques et détail par bâtiment.

CHAPITRE 7

Discussion et limites

Les six chapitres précédents établissent des résultats vérifiés, mais construits sur des choix de périmètre et des données qui bornent leur portée. Ce chapitre revient sur ces limites plutôt que d'en ajouter de nouvelles : transférabilité des données sources, taille des échantillons mobilisés au chapitre 6, et choix de modélisation délibérément écartés.

7.1 Portée et transférabilité

Le choix méthodologique du §1.1 (recours à ResStock faute de base résidentielle française comparable) pèse sur l'ensemble du rapport et n'est pas un détail cosmétique : le chapitre 3 montre par exemple que 43,8% seulement des bâtiments américains ont un thermostat programmable pour le chauffage, un chiffre sans valeur transposable au parc français sans donnée comparable. Toute utilisation opérationnelle des déterminants identifiés ici (zone climatique, agrégats d'enveloppe, jours types) devra être revalidée sur des données françaises dès qu'elles seront disponibles.

Le recentrage **tout-électrique**, décidé en cours de stage pour la cohérence du périmètre (chapitres 4 à 6), a le même effet à plus petite échelle : les 64 062 logements tout-électriques plain-pied du chapitre 5 et les 100 bâtiments du chapitre 6 ne représentent qu'une fraction du parc ResStock complet (549 971 bâtiments). Le §3.5 rappelle que le gaz naturel pèse encore 1 479 TWh au niveau national, quasi autant que l'électricité, une part significative du parc reste donc hors du périmètre étudié en détail dans ce rapport.

7.2 Limites méthodologiques

Taille des échantillons au chapitre 6. Le clustering multivarié et le modèle RNN+MLP reposent sur 100 bâtiments, contre 64 062 pour la modélisation LightGBM du chapitre 5, deux ordres de grandeur d'écart. La partie B du §6.3 (extrapolation annuelle) est la plus exposée : 70 exemples d'entraînement et 15 bâtiments de test seulement, avec un biais net sur le bâtiment le plus consommateur du test (sous-estimé de ~28%, figure 6.11). Le notebook source le signale explicitement : ces résultats sont un signal réel, pas une conclusion définitive.

Ambiguïté du clustering à l'échelle du panel. Le §6.2 retient $k = 6$ par méthode du coude, mais le score de silhouette y culmine à $k = 2$ (0,33) et décroît ensuite, signe que les 6 régimes identifiés forment un *continuum* de comportements plus que des catégories nettement séparées. La typologie reste utile pour décrire le panel (température, amplitude, axe matin/soir), mais ne doit pas être lue comme une segmentation définitive du parc en 6 profils de ménages.

Biais sur les valeurs extrêmes. Le modèle RNN+MLP de la partie A (§6.3) sous-estime systématiquement les pointes de consommation les plus fortes (figure 6.9) - un biais prudent plutôt qu'aberrant, mais qui borne la fiabilité du modèle pour des usages qui viseraient spécifiquement la détection de pics (effacement, alerte de dépassement).

7.3 Choix de modélisation écartés

Le §5.1 compare le LightGBM à une simple baseline de persistance/naïve, pas à d'autres familles de modèles : un MLP avait été envisagé, mais sans justification liée à la nature des métadonnées (catégorielles, tabulaires, mélange d'échelles), contrairement à LightGBM, qui les gère nativement et reste cohérent avec l'objectif d'interprétabilité physique du chapitre 4. Il a donc été écarté plutôt que présenté sans justification. Une comparaison LightGBM/MLP motivée, par exemple sur les interactions non linéaires entre agrégats physiques, resterait une extension raisonnable non menée ici.

CHAPITRE 8

Conclusion et perspectives

8.1 Synthèse

Le fil conducteur annoncé en introduction se vérifie à chaque échelle abordée : le climat structure la consommation électrique résidentielle avant tout autre facteur. À l'échelle annuelle, la zone climatique ASHRAE domine la dispersion entre bâtiments (chapitre 2) et reste, une fois le modèle prédictif entraîné, son déterminant n°1 - latitude et longitude météo pèsent 18,4% de l'importance LightGBM, devant l'enveloppe elle-même (§5.2). À l'échelle journalière, c'est encore le climat qui sépare les jours types d'un même bâtiment (§6.1) et les régimes du panel de 100 bâtiments (§6.2). À l'échelle horaire enfin, c'est le chauffage, piloté par un thermostat programmable, qui porte, à lui seul, les pics de consommation d'un foyer type (§6.1).

Entre ces deux bornes, le bâti et le comportement expliquent la dispersion résiduelle (chapitre 3) : 108 attributs bruts, propres au parc états-unien, se réduisent à 83 features sans perte de performance notable (§4.2), et un LightGBM entraîné sur le périmètre tout-électrique atteint $R^2 = 0,9254$, nette amélioration par rapport au premier modèle du stage avant le recentrage tout-électrique (§5.1). La dynamique temporelle (chapitre 6) ajoute ce que l'analyse annuelle ne pouvait pas montrer : des jours types identifiables, un panel où aucun bâtiment ne domine un régime donné, et un modèle hybride RNN+MLP qui bat une simple persistance horaire ($R^2 = 0,877$ contre 0,827) tout en restant prudent sur les extrêmes.

Le rapport livre ainsi une chaîne complète et reproductible, du nettoyage des métadonnées brutes à la prévision horaire, plutôt qu'un unique modèle final. Chaque étape reste vérifiable indépendamment (source notebook citée à chaque résultat), condition nécessaire pour que ce travail serve de point de départ à la suite du programme FlexiMax plutôt que d'une boîte noire.

8.2 Perspectives

Les limites identifiées au chapitre 7 dessinent assez directement les prochaines étapes.

Élargir le panel du chapitre 6. 100 bâtiments suffisent pour poser le cadre méthodologique du clustering multivarié et du modèle RNN+MLP, mais pas pour en valider les résultats avec la même robustesse que les 64 062 logements du chapitre 5. Le pipeline de téléchargement (§6.2) est déjà en place : l'étendre est une extension directe, en particulier pour fiabiliser la partie B du §6.3 (70 exemples d'entraînement seulement).

Relier clustering et modèles supervisés. Les jours types du §6.1 et les régimes du panel (§6.2) restent aujourd'hui une lecture descriptive, jamais réinjectée dans le modèle prédictif. Utiliser l'appartenance à un cluster comme feature supplémentaire du RNN+MLP (§6.3) - notamment pour la partie B, où le signal manque - est une piste naturelle non explorée ici.

Généraliser la décomposition par poste. Le §6.1 montre, sur un seul bâtiment, que le chauffage porte les pics de consommation. Étendre cette décomposition à l'échelle du panel confirmerait, ou nuancerait, si ce résultat se généralise à des foyers aux profils météo, revenus et équipements différents.

Comparer avec une désagrégation exogène. Une autre approche du projet FlexiMax prédit le niveau annuel par LightGBM puis le désagrège heure par heure via un GRU piloté par la météo et le calendrier (pas la consommation passée), sur un panel plus large. Les deux méthodes répondent à des questions différentes - prévision autorégressive ici, désagrégation d'un total déjà connu là - une comparaison à périmètre égal resterait à mener.

Comparer les architectures avec une justification explicite. Comme noté au §7.3, une comparaison LightGBM/MLP (ou GRU/LSTM/SimpleRNN, déjà paramétrable dans `build_hybrid_model`) resterait à mener, motivée par une hypothèse claire plutôt que par la seule disponibilité du modèle.

Valider sur données françaises. La limite la plus structurante (§7.1) - c'est la condition pour que ce travail dépasse le cadre du stage.

Bibliographie

- [1] Reyna, J., Fontanini, A., Present, E., Liu, L., Adhikari, R., Bianchi, C., et al., *ResStock Technical Reference Documentation v3.3.0*, National Renewable Energy Laboratory (NREL), Golden, CO, 2025. <https://research-hub.nrl.gov/en/publications/resstock-technical-reference-documentation-v330/>
- [2] National Renewable Energy Laboratory (NREL), *ResStock – Residential Building Stock Modeling*. Site officiel du projet. <https://resstock.nrl.gov/>
- [3] ADEME, *Appel à Projets de Recherche (APR) – Vers des bâtiments responsables 2026*, Programme France 2030, ADEME, 2025. <https://agirpoulatransition.ademe.fr/entreprises/aides-financieres/catalogue/aap/appel-projets-de-recherche-vers-des-batiments-responsables-2026>
- [4] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.-Y., *LightGBM : A Highly Efficient Gradient Boosting Decision Tree*, Proceedings of the 31st Conference on Neural Information Processing Systems (NeurIPS 2017), p. 3149–3157, 2017. <https://dl.acm.org/doi/10.5555/3294996.3295074>
- [5] Pedregosa, F., Varoquaux, G., Gramfort, A., et al., *Scikit-learn : Machine Learning in Python*, Journal of Machine Learning Research, vol. 12, p. 2825–2830, 2011. <https://www.jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf>
- [6] Chollet, F. et al., *Keras*, 2015. <https://keras.io>
- [7] MacQueen, J., *Some Methods for Classification and Analysis of Multivariate Observations*, Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability, vol. 1, p. 281–297, 1967. <https://projecteuclid.org/ebooks/berkeley-symposium-on-mathematical-statistics-and-probability/Proceedings-of-the-Fifth-Berkeley-Symposium-on-Mathematical-Statistics-and-chapter/Some-methods-for-classification-and-analysis-of-multivariate-observations/bsmsp/1200512992>
- [8] Alvarez, C., *États-Unis : le dérèglement climatique va accroître la pauvreté et les inégalités*, Novethic, 25 juillet 2017. <https://www.novethic.fr/actualite/environnement/climat/isr-rse/etats-unis-le-climat-va-accroitre-la-pauvrete-et-les-inegalites-144602.html>

Annexes

Deux compléments techniques au rapport : le détail variable par variable des attributs `in.*` encodés (§A.1), et une vue d'ensemble du pipeline de notebooks qui produit l'ensemble des résultats cités (§A.2).

A.1 Description détaillée des attributs `in.*` encodés

Description des variables - `X_aggregates.parquet` (statut réel : supprimé / conservé)

Modèle réduit « physique » - subset filtré (64 062 logements : maisons plain-pied, chauffage électrique, sans VE/piscine/PV).

★ **agrégat** = agrégat physique ajouté ✗ **supprimé** = attribut supprimé
✓ **conservé** = attribut conservé

Bilan : 108 attributs → 83 features - détail du calcul en §4.2.

Variable	Description	Avant (ex.)	Après (ex.)	Encodage appliqué	Groupe	Statut
0	Agrégats physiques - modèle RC (remplacent le bloc enveloppe)					
UA	Déperdition par transmission des parois (W/K)	~30 attributs	≈390 W/K	$\sum_i U(R_i) A_i + U_{\text{fen}} A_{\text{fen}} + 1,14 A_{\text{porte}}$	RC	★ agrégat
H_ve	Déperdition par renouvellement d'air (W/K)	ACH50	≈75 W/K	$0,34 (\text{ACH}50/20) V$	RC	★ agrégat
C	Inertie thermique - stockage (kJ/K)	type mur	≈11 600 kJ/K	$C_{\text{classe}} \times A_{\text{pl}}$ (ISO 13790)	RC	★ agrégat
A_solaire	Surface solaire équivalente (m²)	SHGC+orient.	≈8 m²	$\text{SHGC} \cdot 0,9 \cdot A_{\text{fen}} \cdot \sum_d \frac{d_k}{d} p(\theta_k)$	RC	★ agrégat
compacite	Coefficient de forme (m ⁻¹)	surfaces	≈0,85	$(\sum A_{\text{parois}})/V$	RC	★ agrégat
1	Variables Socio-Économiques					

Suite page suivante...

Variable	Description	Avant (ex.)	Après (ex.)	Encodage appliqué	Groupe	Statut
in.income	Revenu annuel du ménage (tranche)	50000-59999	54 999.5	Midpoint (\$)	Socio-Éco	✓ conservé
in.federal_poverty_level	Ratio revenu / seuil de pauvreté fédéral	200-300%	2.5	Midpoint → ratio	Socio-Éco	✓ conservé
in.area_median_income	Ratio revenu ménage / médian de la zone	0.9	0.9	Numérique	Socio-Éco	✓ conservé
in.state_metro_median_incc	Ratio revenu médian état/métropole	1.1	1.1	Numérique	Socio-Éco	✓ conservé
in.tenure	Statut d'occupation (propriétaire/locataire)	Owner	1	Binaire	Socio-Éco	✓ conservé
in.household_has_tribal_pe	Membres d'une tribu amérindienne	No	0	Binaire	Socio-Éco	✓ conservé
in.aiannh_area	Zone tribale reconnue (AIANNH)	No	0	Binaire	Socio-Éco	✓ conservé
2 Variables Occupants						
in.occupants	Nombre d'occupants	3	3.0	Numérique	Occupants	✓ conservé
in.bedrooms	Nombre de chambres	4	4	Numérique	Occupants	✓ conservé
in.vacancy_status	Logement occupé ou vacant	Occupied	1	Binaire	Occupants	✓ conservé
in.usage_level	Niveau global d'utilisation	Medium	1	Label ordinal	Occupants	✓ conservé
in.hot_water_fixtures	Coefficient d'utilisation ECS	1.1	1.1	Numérique	Occupants	✓ conservé
3 Variables Météo						
in.weather_file_latitude	Latitude du fichier météo TMY	34.75	34.75	Numérique	Météo	✓ conservé
in.weather_file_longitude	Longitude du fichier météo TMY	-87.61	-87.61	Numérique	Météo	✓ conservé
4 Enveloppe Thermique (fondue dans les agrégats UA / H_ve / C / A_solaire / compacité)						
<i>4.1 Isolation</i>						
in.insulation_ceiling	R assemblage plafond/combles	R-30	31.6	Lookup R nominale → assemblage	Enveloppe	✗ supprimé
in.insulation_wall	R assemblage murs extérieurs	Wood Stud, R-15	12.1	Lookup type + R	Enveloppe	✗ supprimé
in.insulation_roof	R assemblage toiture	Finished, R-19	21.2	Lookup fini + R	Enveloppe	✗ supprimé
in.insulation_floor	R assemblage plancher	Ceiling R-19	22.6	Lookup R	Enveloppe	✗ supprimé

Suite page suivante...

Variable	Description	Avant (ex.)	Après (ex.)	Encodage appliqué	Groupe	Statut
in.insulation_foundation_w	R isolation murs de fondation	Wall R-10	10.0	Extraction R	Enveloppe	✗ supprimé
in.slab_perimeter_r	R isolation périphérique dalle	2ft R10 Perim.	10.0	Extraction R	Enveloppe	✗ supprimé
in.slab_under_r	R isolation sous dalle	2ft R10 Under	10.0	Extraction R	Enveloppe	✗ supprimé
<i>4.2 Étanchéité, Vitrage et Géométrie</i>						
in.air_leakage_to_outside_	Infiltration à 50 Pa (ACH50)	7.0	7.0	Numérique	Enveloppe	✗ supprimé
in.window_ufactor	Coefficient U du vitrage	U-1.16	1.16	Extraction	Enveloppe	✗ supprimé
in.window_shgc	Facteur solaire du vitrage (SHGC)	SHGC 0.76	0.76	Extraction	Enveloppe	✗ supprimé
in.window_front	Surface vitrée façade principale (ft²)	12 ft²	12.0	Numérique	Enveloppe	✗ supprimé
in.geometry_floor_area	Surface habitable (m²)	1000-1499	116.1	Midpoint → m²	Enveloppe	✗ supprimé
in.geometry_stories	Nombre d'étages	1	1	Numérique	Enveloppe	✗ supprimé
in.geometry_attic_type	Type de combles	Vented Attic	1	Label ordinal	Enveloppe	✓ conservé
in.geometry_foundation_ty	Type de fondation	Slab	2	Label ordinal	Enveloppe	✗ supprimé
in.geometry_garage	Présence et taille du garage	None	0	Label	Enveloppe	✗ supprimé
in.vintage	Âge du bâtiment (années)	1990s	29	Midpoint décennie	Enveloppe	✓ conservé
in.roof_material	Absorptance solaire toiture	Comp. Shingles	0.44	Extraction	Enveloppe	✗ supprimé
in.orientation_sin	Sinus de l'orientation	Northwest	-0.707	Encodage circulaire	Enveloppe	✗ supprimé
in.orientation_cos	Cosinus de l'orientation	Northwest	0.707	Encodage circulaire	Enveloppe	✗ supprimé
in.wall_exterior_finish_r	R de la finition extérieure	Brick	0.7	Extraction R	Enveloppe	✗ supprimé
in.wall_finish_dark	Finition de couleur foncée	Brick, Dark	1	OHE binaire	Enveloppe	✗ supprimé
in.wall_finish_brick	Finition en brique	Brick	1	OHE binaire	Enveloppe	✗ supprimé
in.wall_finish_none	Pas de finition spécifique	Wood	0	OHE binaire	Enveloppe	✗ supprimé
in.wall_finish_shingle	Finition en bardeau	Vinyl	0	OHE binaire	Enveloppe	✗ supprimé
in.wall_finish_stucco	Finition en stuc	Vinyl	0	OHE binaire	Enveloppe	✗ supprimé
in.wall_finish_vinyl	Finition en vinyle	Vinyl	1	OHE binaire	Enveloppe	✗ supprimé
in.wall_finish_wood	Finition en bois	Wood	1	OHE binaire	Enveloppe	✗ supprimé
<i>4.3 Voisinage</i>						

Suite page suivante...

Variable	Description	Avant (ex.)	Après (ex.)	Encodage appliqué	Groupe	Statut
in.horiz_loc_Middle	Position centrale dans une rangée	Middle	1	OHE binaire	Enveloppe	✗ supprimé
in.horiz_loc_Right	Position droite dans une rangée	Left	0	OHE binaire	Enveloppe	✗ supprimé
in.neighbor_distance_ft	Distance au voisin (pieds)	15 ft	15.0	Extraction	Enveloppe	✗ supprimé
in.neighbor_both_sides	Voisins des deux côtés	L/R 15ft	1.0	Binaire dérivé	Enveloppe	✗ supprimé
in.corridor	Présence d'un couloir commun	0	0	Binaire	Occupants	✓ conservé
5 Systèmes Énergétiques						
<i>5.2 Chauffage et Climatisation (HVAC)</i>						
in.hvac_has_ducts	Présence d'un réseau de gaines	Yes	1	Binaire	Systèmes	✓ conservé
in.duct_leakage	Fuite des gaines vers l'extérieur	10% Leakage	0.1	Extraction % → ratio	Systèmes	✓ conservé
in.duct_insulation	R-value isolation des gaines	R-8	8	Extraction R	Systèmes	✓ conservé
in.duct_location_int	Emplacement des gaines	Living Space	1	Label	Systèmes	✓ conservé
in.hvac_cooling_efficiency	SEER de la climatisation	SEER 13	13.0	Extraction SEER	Systèmes	✓ conservé
in.hvac_cooling_partial_sf	Fraction climatisée	1.0	1.0	Numérique	Systèmes	✓ conservé
in.hvac_has_zonal_electric	Chauffage électrique zonal	No	0	Binaire	Systèmes	✓ conservé
in.cooling_setpoint	Consigne de climatisation (°C)	75F	23.9	°F→°C	Systèmes	✓ conservé
in.cooling_setpoint_has_of	Programmation horaire clim	Yes	1	Binaire	Systèmes	✓ conservé
in.cooling_setpoint_offset	Amplitude du décalage clim	-3°F	-16.7	Numérique	Systèmes	✓ conservé
in.heating_setpoint	Consigne de chauffage (°C)	68F	20.0	°F→°C	Systèmes	✓ conservé
in.heating_setpoint_has_of	Programmation horaire chauffage	No	0	Binaire	Systèmes	✓ conservé
in.heating_setpoint_offset	Amplitude du décalage chauffage	-8°F	-17.8	Numérique	Systèmes	✓ conservé
<i>5.3 Eau Chaude Sanitaire (DHW)</i>						
in.water_heater_efficiency	Rendement du chauffe-eau (EF/COP)	Elec. Standard	0.92	Extraction EF/COP	Systèmes	✓ conservé
in.water_heater_in_unit	Chauffe-eau dans le logement	Yes	1	Binaire	Systèmes	✓ conservé
in.water_heater_technology	Technologie indirecte (OHE)	Indirect	1	OHE binaire	Systèmes	✓ conservé
in.water_heater_technology	Ballon de stockage (OHE)	Storage	1	OHE binaire	Systèmes	✓ conservé
in.water_heater_technology	Instantané sans réservoir (OHE)	Tankless	1	OHE binaire	Systèmes	✓ conservé

Suite page suivante...

Variable	Description	Avant (ex.)	Après (ex.)	Encodage appliqué	Groupe	Statut
in.water_heater_fuel_fuel_	Combustible fioul (OHE)	Fuel Oil	1	OHE binaire	Systèmes	✓ conservé
in.water_heater_fuel_natur	Combustible gaz naturel (OHE)	Natural Gas	1	OHE binaire	Systèmes	✓ conservé
in.water_heater_fuel_propa	Combustible propane (OHE)	Propane	1	OHE binaire	Systèmes	✓ conservé
in.water_heater_location_s	Espace semi-conditionné (OHE)	Garage	1	OHE binaire	Systèmes	✓ conservé
in.water_heater_location_u	Espace non conditionné (OHE)	Attic	1	OHE binaire	Systèmes	✓ conservé
in.dishwasher_kwh	Conso lave-vaisselle (kWh/an)	290	290.0	Numérique	Systèmes	✓ conservé
in.has_dishwasher	Présence d'un lave-vaisselle	Yes	1	Binaire	Systèmes	✓ conservé
6 Classification des Usages Électriques						
in.clothes_dryer_efficienc	Rendement du sèche-linge (CEF)	Electric	2.7	CEF par combustible	Usages	✓ conservé
in.clothes_dryer_has	Présence d'un sèche-linge	Electric	1	Binaire	Usages	✓ conservé
in.clothes_dryer_electric	Sèche-linge électrique (OHE)	Electric	1	OHE binaire	Usages	✓ conservé
in.clothes_dryer_gas	Sèche-linge au gaz (OHE)	Electric	0	OHE binaire	Usages	✓ conservé
in.clothes_washer_efficier	Efficacité du lave-linge (IMEF)	Standard	0.95	Extraction IMEF	Usages	✓ conservé
in.clothes_washer_has	Présence d'un lave-linge	Standard	1	Binaire	Usages	✓ conservé
in.refrigerator_ef	EF du réfrigérateur principal	EF 15.9	15.9	Extraction EF	Usages	✓ conservé
in.refrigerator_has	Présence d'un réfrigérateur	EF 15.9	1	Binaire	Usages	✓ conservé
in.lighting_efficiency	Efficacité de l'éclairage	100% CFL	2	Label ordinal	Usages	✓ conservé
in.misc_extra_refrigerator	EF frigo/congélateur supplémentaire	EF 10.5	10.5	Extraction EF	Usages	✓ conservé
in.misc_extra_refrigerator	Présence 2 ^e frigo/congélateur	EF 10.5	1	Binaire	Usages	✓ conservé
in.misc_freezer_ef	EF du congélateur dédié	EF 12.0	12.0	Extraction EF	Usages	✓ conservé
in.misc_gas_fireplace_pres	Cheminée décorative au gaz	No	0	Binaire	Usages	✓ conservé
in.misc_gas_grill_present	Barbecue au gaz raccordé	No	0	Binaire	Usages	✓ conservé
in.misc_gas_lighting_prese	Éclairage extérieur au gaz	No	0	Binaire	Usages	✓ conservé
in.has_hot_tub	Présence d'un spa/jacuzzi	No	0	Binaire	Usages	✓ conservé
in.hot_tub_electric	Spa électrique (OHE)	Electric	1	OHE binaire	Usages	✓ conservé
in.misc_hot_tub_gas	Spa au gaz (OHE)	Gas	1	OHE binaire	Usages	✓ conservé

Suite page suivante...

Variable	Description	Avant (ex.)	Après (ex.)	Encodage appliqué	Groupe	Statut
in.has_pool	Présence d'une piscine	No	0	Binaire	Usages	✓ conservé
in.pool_heater_present	Chauffage de piscine présent	No	0	Binaire	Usages	✓ conservé
in.pool_heater_electric	Chauffage piscine électrique (OHE)	Electric	1	OHE binaire	Usages	✓ conservé
in.pool_heater_gas	Chauffage piscine au gaz (OHE)	Gas	1	OHE binaire	Usages	✓ conservé
in.has_well_pump	Présence d'une pompe de puits	Yes	1	Binaire	Usages	✓ conservé
in.has_ceiling_fan	Présence d'un ventilateur de plafond	Yes	1	Binaire	Usages	✓ conservé
in.ceiling_fan_used	Ventilateur utilisé en saison chaude	Yes	1	Binaire	Usages	✓ conservé
7 Part des Usages Blanc et Brun						
in.plugin_loads	Intensité des prises et petits appareils	134%	1.34	Ratio %/100	Blanc/Brun	✓ conservé
in.plugin_load_diversity	Diversité temporelle des prises	100%	1.0	Ratio %/100	Blanc/Brun	✓ conservé
in.clothes_dryer_usage_level	Multiplicateur d'usage sèche-linge	1.0	1.0	Numérique	Blanc/Brun	✓ conservé
in.refrigerator_usage_level	Multiplicateur d'usage réfrigérateur	1.0	1.0	Numérique	Blanc/Brun	✓ conservé
8 Infrastructure Électrique						
in.electric_panel_service_capacity	Puissance du tableau (ampères)	125 A	125.0	Numérique	Infra	✓ conservé
in.electric_panel_breaker_count	Emplacements de disjoncteurs	25	25.0	Numérique	Infra	✓ conservé
9 Production Photovoltaïque (PV)						
in.has_pv	Présence d'un système PV	No	0	Binaire	PV	✓ conservé
in.pv_system_size	Puissance installée PV (kW DC)	None	0.0	Extraction ; None→0	PV	✓ conservé
10 Mobilité Électrique (EV)						
in.electric_vehicle_charge_probability	Probabilité de recharge à domicile	0.9	0.9	Numérique	EV	✓ conservé
in.electric_vehicle_charge_level	Niveau du chargeur VE	None	0	Label	EV	✓ conservé
in.electric_vehicle_miles_annual	Kilométrage annuel VE	9000	9000.0	Numérique	EV	✓ conservé

A.2 Pipeline complet des notebooks

Chaque résultat cité dans ce rapport est reproductible à partir d'un notebook source précis; le tableau ci-dessous en donne la vue d'ensemble, dans l'ordre d'exécution.

TABLE A.2 – Vue d'ensemble du pipeline de notebooks du dépôt FlexiMax.

Étape	Contenu
01_exploration	Exploration initiale (enveloppe thermique, HVAC, occupants, climat/localisation, vue d'ensemble des groupes in.*).
02_nettoyage	Nettoyage des métadonnées → <code>metadata_clean.parquet</code> .
03_visualisation	Classification métier des variables, décomposition nationale par usage/vecteur énergétique, visualisation du sous-ensemble national.
04_features	Transformations numériques, encodage catégoriel, feature engineering physique, préparation finale → <code>X.parquet/Y.parquet</code> .
05_deeplearning	Modélisation LightGBM (électricité, Global vs Physique, par usage), clustering stratifié pour le split partagé.
06_timeseries	Extraction OEDI, clustering des profils (univarié/multi-varié), RNN/MLP hybride pour la prévision.

Cette chaîne, du nettoyage des métadonnées brutes à la prévision horaire, couvre l'intégralité des résultats présentés dans ce rapport.

A.3 Profils moyens par cluster en valeurs réelles

La figure 6.7 (§6.2) montre les profils de forme moyens par cluster en z-score, l'axe sur lequel le clustering est effectivement réalisé : les valeurs négatives et positives y représentent un écart à la consommation moyenne du jour, pas une consommation réelle. À titre complémentaire, la figure A.1 ci-dessous moyenne directement les profils bruts (en kWh) par cluster. Les deux lectures sont cohérentes : les clusters 3 et 5 (les plus froids, §6.2) affichent aussi les niveaux réels les plus élevés (5 à 8 kWh), tandis que les clusters 0 et 4 restent les plus bas (1 à 2 kWh), confirmant en valeurs réelles le lien température-amplitude déjà établi. Nuance à garder en tête : les clusters étant formés surtout sur la forme et non sur le niveau, un cluster peut mélanger des logements de tailles différentes, la moyenne en kWh brut peut donc être influencée par les plus gros consommateurs du cluster.




FIGURE A.1 – Profils moyens par cluster en valeurs réelles (kWh), complément à la figure 6.7.